Sesión 7 · Modelos open source: Hugging Face Ecosystem

Fine-tuning de un modelo de texto abierto

Enunciado

Ajusta un modelo abierto para clasificar incidencias ficticias de soporte y devolver un JSON con categoría, prioridad y una respuesta breve. Compara entrenarlo con mejorar únicamente las instrucciones del modelo.

Explicación completa del ejercicio

Trabajo obligatorio. Completa estas tareas con datos sintéticos. No incluyas información personal ni claves de acceso en los datos, el código o las capturas.

Prepara el entorno y los datos. Usa Qwen3-0.6B con Transformers, Datasets, TRL y PEFT. Configura `OPEN_MODEL_ID` y registra las versiones. Separa 150–300 ejemplos para entrenamiento, 30 para validación y 30 para prueba, sin duplicados entre grupos. Define las categorías, prioridades y campos del JSON antes de comenzar.

Entrena y compara. Ejecuta tres condiciones: modelo base con instrucciones básicas, modelo base con unos pocos ejemplos en el prompt (few-shot) y modelo ajustado con LoRA. Usa una configuración fija de LoRA, sin buscar hiperparámetros. El modelo base y el ajustado recibirán las mismas instrucciones básicas. Los ejemplos few-shot saldrán del entrenamiento; mejora ese prompt con validación y no lo cambies después de ver el test.

Mantén las mismas reglas. Usa el mismo chat template en entrenamiento e inferencia, con `enable_thinking=False`. El chat template es la plantilla que separa los mensajes de usuario y asistente; no dupliques sus tokens especiales. En las tres condiciones mantén los mismos parámetros de generación y el mismo límite de tokens de salida.

Evalúa las respuestas originales. Pide JSON mediante el prompt: no uses JSON mode, herramientas que impongan el formato, reparación automática ni reintentos para corregirlo. Aplica un único validador. Calcula el porcentaje de JSON válido y de aciertos en categoría y prioridad sobre los 30 casos. Una salida que no se pueda interpretar cuenta como error. Conserva este protocolo y los datos para la Sesión 8; no es obligatorio que el ajuste obtenga mejores resultados.

Publica el adaptador. Súbelo a Hugging Face Hub, en un repositorio privado si lo prefieres, y añade una model card con modelo base, datos, configuración, resultados, licencia y limitaciones. Recárgalo desde el Hub y ejecuta una predicción. No necesitas contratar un endpoint de inferencia.

Ampliación opcional. Analiza tres errores y plantea mejoras sin volver a ajustar el sistema sobre los casos del test.

Entrega y valoración. Entrega código, datos sintéticos separados, resultados originales, tabla comparativa y enlace al adaptador. Se valorarán la separación de datos, la comparación justa, la posibilidad de repetir el entrenamiento y la recarga desde el Hub.

Dedicación orientativa: 5–7 horas activas con GPU y entorno preparados, sin contar las esperas del entrenamiento.