thePower

S7

Modelos abiertos

Del repositorio a una respuesta en tu equipo



José Antonio Nuevo

13 y 14 de octubre de 2026 · 18:30–20:00

Antes de empezar

Evaluación AI Engineer

Este QR evalúa
la clase anterior.

Mientras respondes…
¿Qué memoria tiene tu equipo?



La pregunta de hoy

¿Qué modelo abierto puedo ejecutar en mi ordenador, cómo lo utilizo y cómo puedo mejorar sus respuestas?

1 canirun.ai
Elegir un modelo para tu equipo

2 Hugging Face
Encontrar, leer y verificar

3 LM Studio
Descargar, cargar y ejecutar

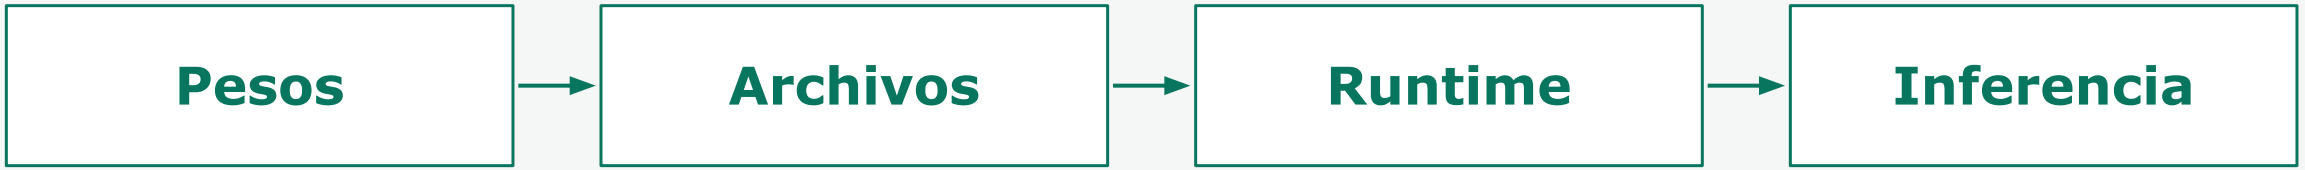
4 isbetter.ai
Comparar respuestas a ciegas

5 Prompting y LoRA
Mejorar, evaluar y publicar

6 Ejercicio y dudas
LoRA de Qwen3-0.6B

Qué son los pesos abiertos

Un modelo de lenguaje calcula, token a token, la continuación más probable de un texto.



Parámetros numéricos que el modelo aprende al entrenar.

Los pesos guardados en disco: Safetensors, GGUF o MLX.

Programa que los carga en memoria: LM Studio, Transformers…

El cálculo que produce la respuesta a tu prompt.

Pesos abiertos: los archivos se pueden descargar y ejecutar con un runtime compatible.

Publicar pesos no obliga a publicar datos ni código de entrenamiento.

Un modelo con pesos abiertos también puede utilizarse por API.

Open-weight, open-source o propietario

	Open-weight	Open-source	Servicio propietario
Pesos descargables	Sí	Sí	No: solo API o app
Datos y código de entrenamiento	No necesariamente	Sí, o información suficiente para reproducirlo	No
Ejecución local y adaptación	Sí, si el hardware y la licencia lo permiten	Sí	Solo lo que ofrezca el proveedor
Licencia	Fija usos y redistribución; puede limitar el uso comercial	Permite usar, estudiar, modificar y compartir	Términos del servicio
Ejemplos	Qwen3-0.6B, Llama	OLMo (Ai2)	Gemini (S8), GPT, Claude

Modelos abiertos según la tarea

Conversación

Chat, resumen y extracción de información.

Razonamiento

Problemas que requieren varios pasos y comprobaciones.

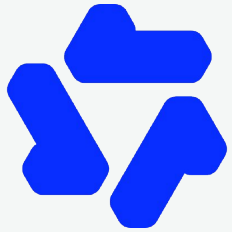
Código

Generar, revisar y depurar programas.

Multimodales

Texto con imágenes, audio o vídeo, según la versión.

Familias chinas: Qwen, DeepSeek y Kimi



Qwen

Alibaba Cloud

Qwen3.8-27B
Qwen3-0.6B

Chat, código,
razonamiento y visión.

Ejemplos: Apache-2.0



DeepSeek

DeepSeek

DeepSeek-V4-Flash

Razonamiento y código.
Gran escala (MoE).

V4-Flash: MIT



Kimi

Moonshot AI

Kimi K3

Agentes y herramientas.
Requiere servidores.

Licencia propia (Kimi K3)

GLM y MiniMax (China) · Gemma (Google)

GLM

Z.ai

GLM-5.3

Código, razonamiento y herramientas.

Licencia propia (GLM-5.3)

MiniMax

MiniMax

MiniMax-M3

Multimodal, código y agentes.

MiniMax Community License

Gemma

Google DeepMind

Gemma 4 E2B

Texto e imagen; audio en algunas variantes.

Gemma 4: Apache-2.0

Gemma (pesos descargables) es distinta de Gemini

Parámetros, memoria y cuantización

Parámetros: Los parámetros de un LLM son los valores numéricos internos que el modelo aprende durante su entrenamiento y que determinan cómo procesa el lenguaje, relaciona conceptos y genera respuestas.

RAM: memoria del sistema, la que usa el procesador (CPU).

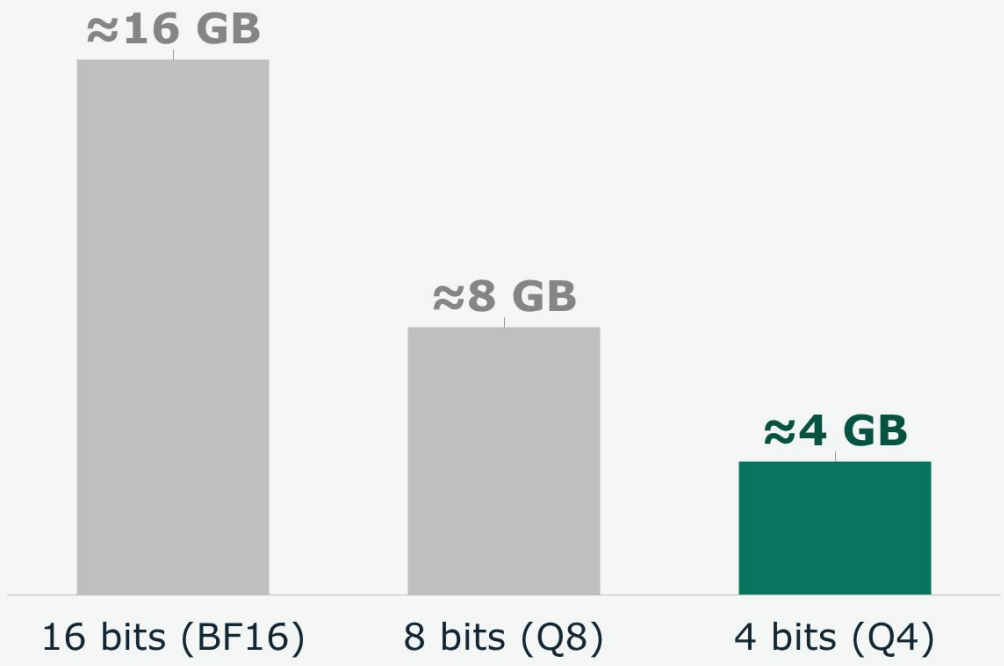
VRAM: memoria de la tarjeta gráfica (GPU).

Memoria unificada: CPU y GPU comparten la misma memoria, como en los Mac con Apple Silicon.

Cuantización: guardar cada peso con menos bits: ocupa menos y puede perder algo de calidad.

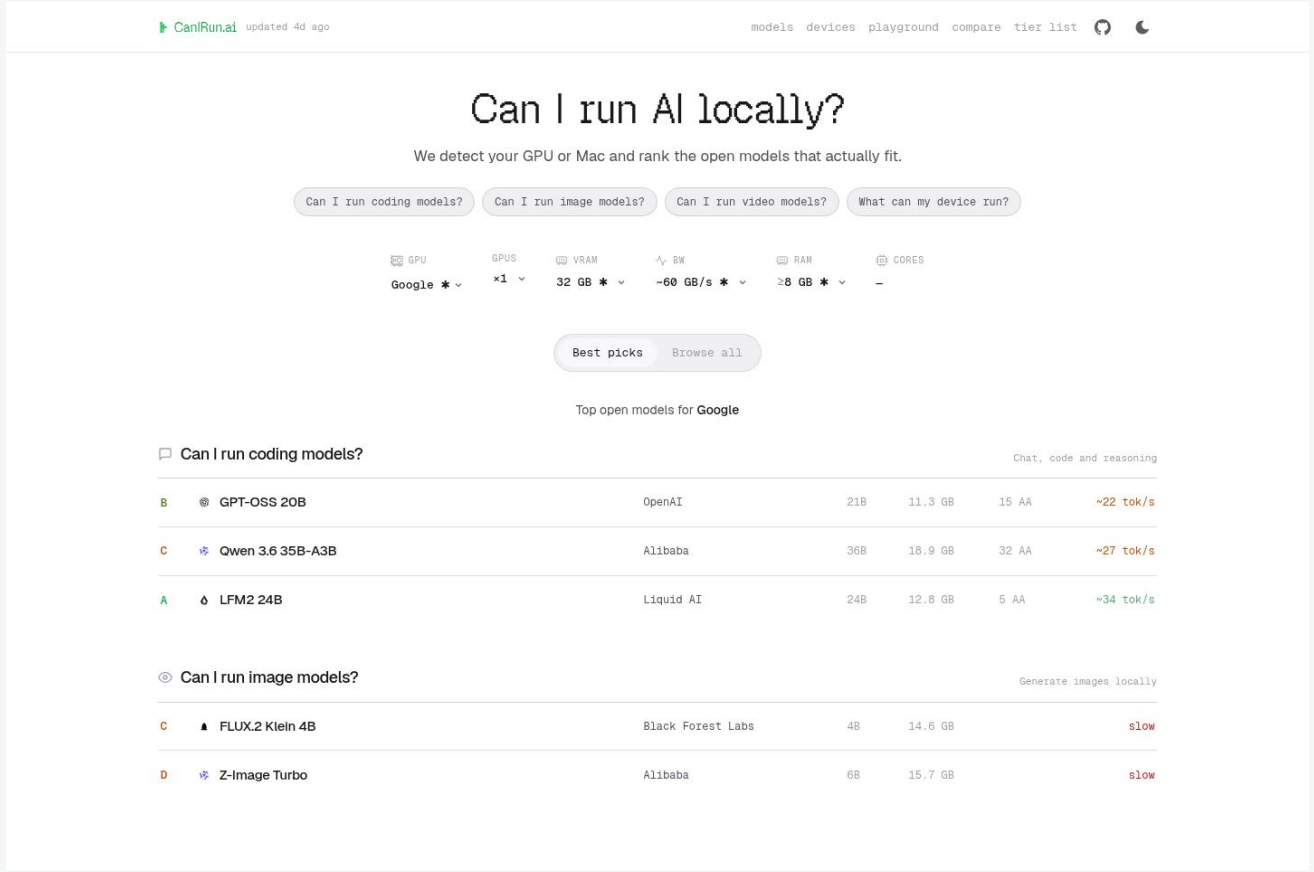
Contexto: cuanto más texto mantiene la conversación, más memoria consume.

Memoria de los pesos de un modelo de 8B



Cálculo teórico: parámetros × bits ÷ 8. El contexto, el runtime y el sistema suman memoria.

¿Qué puede ejecutar mi equipo?



Memoria

¿Cabe en RAM, VRAM o memoria unificada?

Cuantización

Menos bits, menos memoria.

Contexto

Más tokens, más memoria.

¿Qué es Hugging Face?

Una plataforma para encontrar, compartir y probar recursos de IA.

Modelos

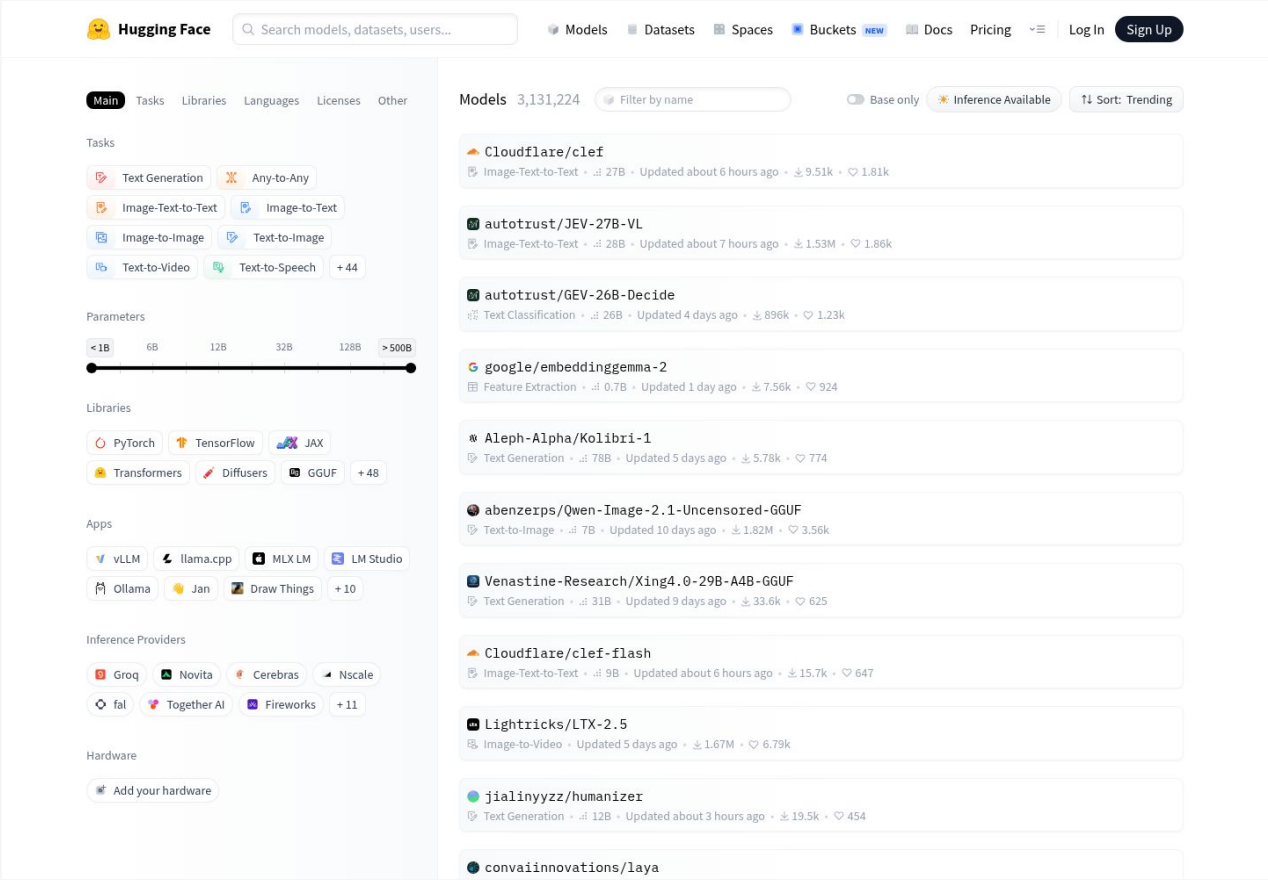
Pesos, fichas y versiones.

Datasets

Datos para entrenar y evaluar.

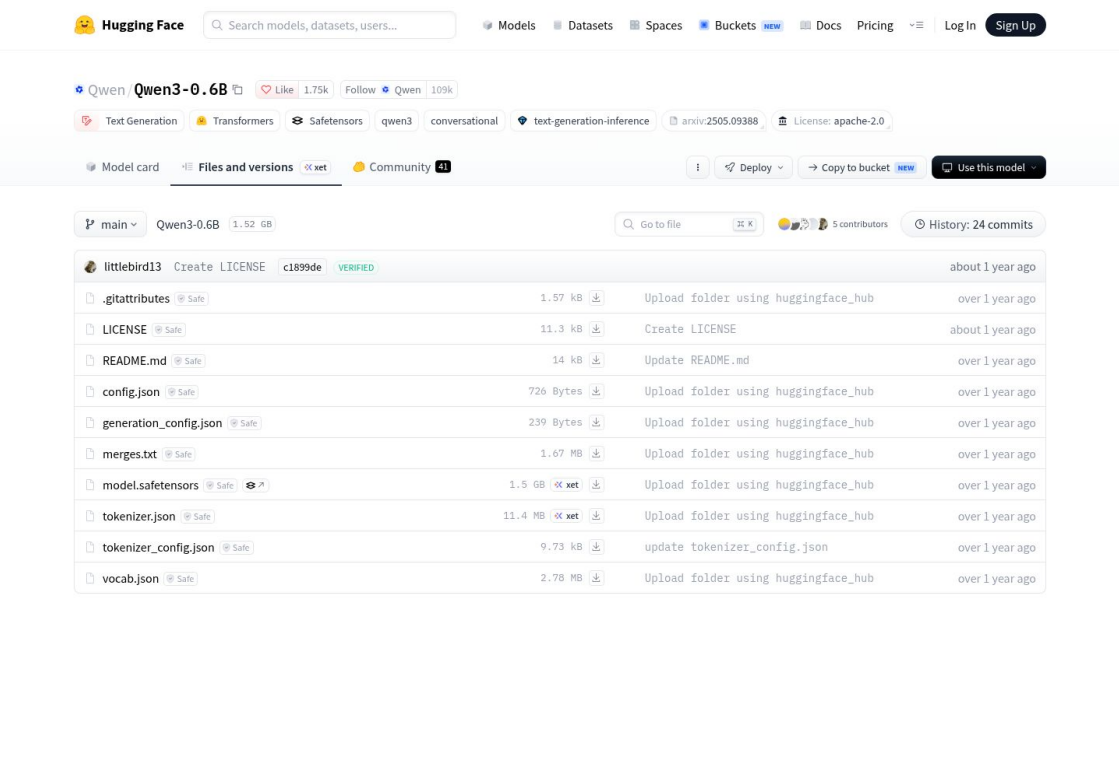
Spaces

Aplicaciones y demos.



Hugging Face: ficha y archivos

Un repositorio reúne documentación, pesos y versiones.



Model card

Objetivo y límites.

Files and versions

Archivos y revisiones.

Autor y licencia

Procedencia y permisos.

Safetensors, GGUF y MLX

Safetensors

Formato habitual de los pesos originales.

Lo usan Transformers y PyTorch.

Base para entrenar con LoRA.

GGUF

Un archivo, casi siempre cuantizado: Q4, Q8…

Lo ejecutan llama.cpp, LM Studio y Ollama.

Funciona en CPU y GPU.

MLX

Framework de Apple para Apple Silicon.

LM Studio lo ejecuta en Mac.

No son intercambiables: descarga el formato que admite tu runtime.

Un derivado GGUF o MLX debe indicar de qué modelo original procede y con qué cuantización.

El archivo compatible con nuestro runtime



Autor y procedencia

Archivo identificado

Carga comprobada

Ruta GGUF de esta demo. Verificamos origen, licencia y compatibilidad del archivo elegido.

¿Qué es LM Studio?

LM Studio

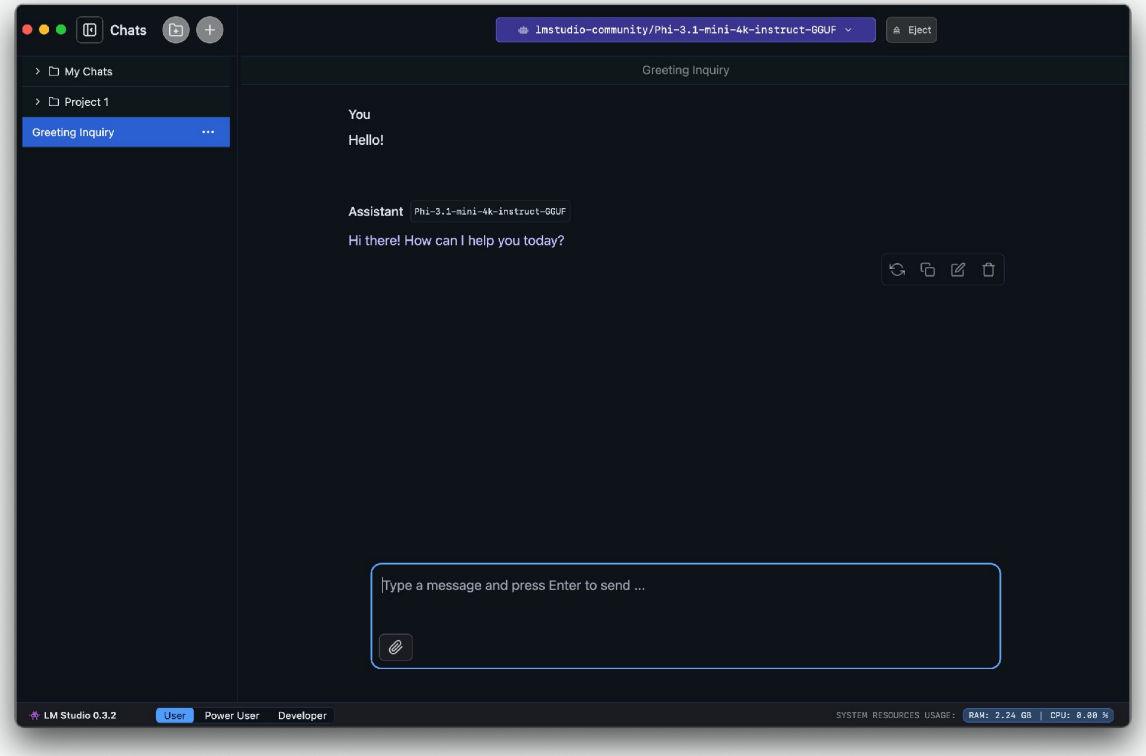
Una aplicación de escritorio
para descargar y ejecutar
modelos compatibles
en tu equipo.

Chat

Conversación con el
modelo cargado.

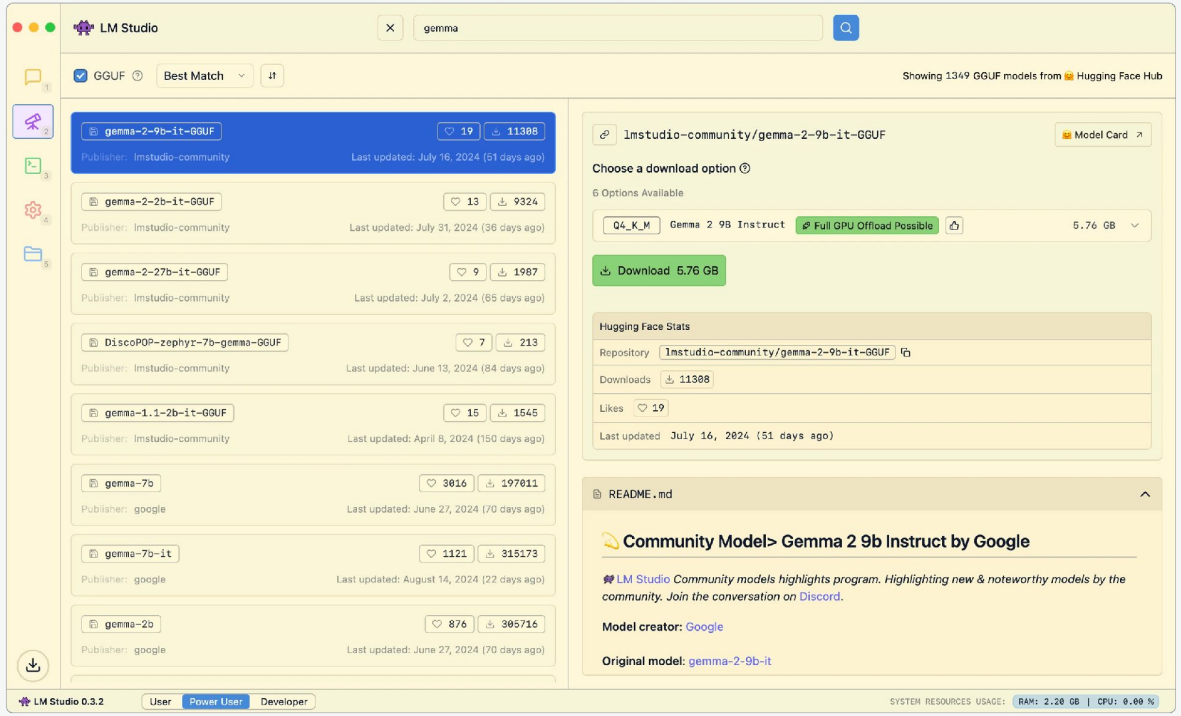
Servidor local

Otras apps consultan
el modelo mediante API.



LM Studio no es un modelo: ejecuta los modelos que descargas. Captura oficial, v0.3.2.

LM Studio: descarga y primer chat



1. Buscar

Nombre o URL.

2. Descargar

El archivo compatible.

3. Cargar

Modelo en memoria.

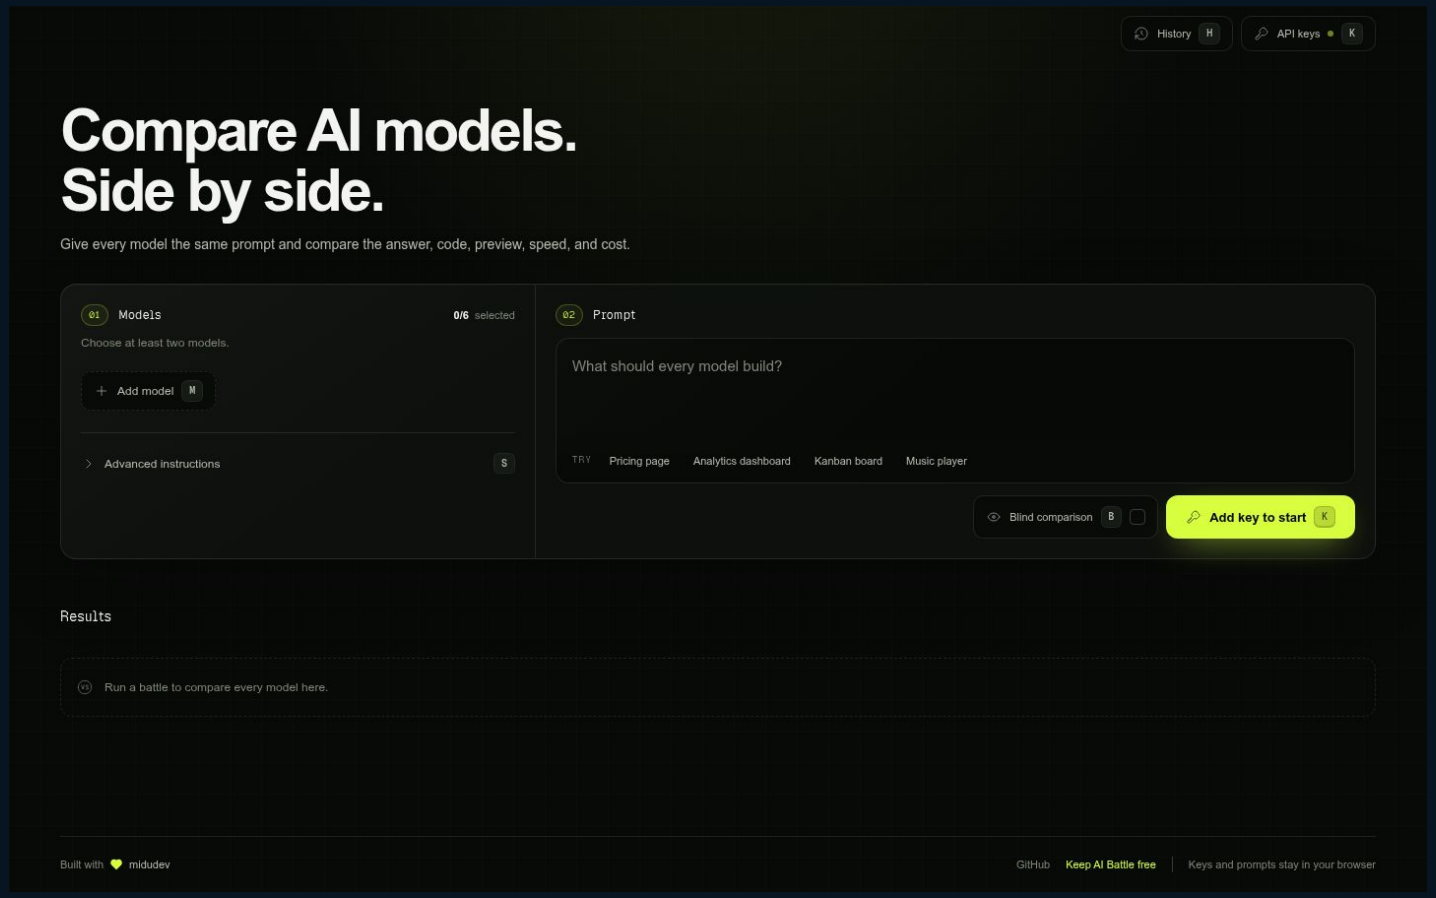
4. Ejecutar

Inferencia local.

5. Consultar

Chat o API local.

isbetter.ai: dos respuestas, un mismo caso



Dos modelos abiertos

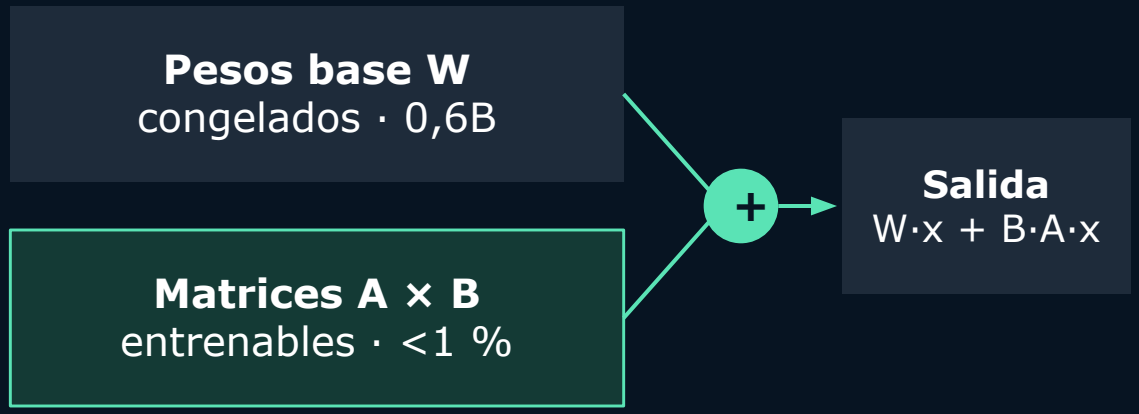
Mismo prompt completo

Voto ciego y una razón

LoRA: cómo funciona y cuándo entrenar

LoRA (Low-Rank Adaptation) congela los pesos del modelo base y entrena solo dos matrices pequeñas que se suman a sus capas.

Cómo funciona



Solo cambian A y B: el adaptador pesa unos MB y se aplica sobre la base sin modificarla.

Cómo se entrena

1. Reunir cientos de pares instrucción → respuesta y separar train y validación.
2. Cargar la base y añadir LoRA: rango r y capas objetivo.
3. Entrenar pocas épocas y vigilar la pérdida en validación.
4. Guardar el adaptador y compararlo con básico y few-shot.

Para qué

Fijar formato, tono o vocabulario de un dominio de forma estable, con poca memoria y sin copiar el modelo entero.

Cuándo hacerlo

Cuando prompting y few-shot fallan en validación. Si faltan datos nuevos o cambiantes, mejor RAG.

PyTorch y el ecosistema para entrenar

PyTorch hace los cálculos; las librerías de Hugging Face añaden encima el modelo, LoRA y el bucle de entrenamiento.

TRL	SFTTrainer: el bucle de entrenamiento supervisado con la plantilla de chat
PEFT	LoraConfig: añade las matrices A y B y guarda solo el adaptador
Transformers	Carga Qwen3-0.6B y su tokenizer desde el Hub
PyTorch	Tensores, gradientes automáticos y ejecución en GPU (CUDA) o Mac (MPS)

Complementos

Datasets
cargar y dividir los datos

Accelerate
repartir entre dispositivos y usar precisión mixta

bitsandbytes
QLoRA: base en 4 bits, solo GPU NVIDIA

Cada capa usa la de abajo: SFTTrainer llama a PEFT, que modifica un modelo de Transformers, que se ejecuta sobre PyTorch.

Un entrenamiento LoRA en pocas líneas

```python
# 1 Datos
data = load_dataset("json", data_files="train.jsonl")["train"]

# 2 Configuración LoRA
lora = LoraConfig(r=16, lora_alpha=32,
                  target_modules=["q_proj", "v_proj"])

# 3 Entrenar
trainer = SFTTrainer(
    model="Qwen/Qwen3-0.6B",
    train_dataset=data,
    peft_config=lora,
    args=SFTConfig(output_dir="qwen3-lora", num_train_epochs=2))
trainer.train()

# 4 Guardar
trainer.save_model("qwen3-lora")
```

1. **Datos**
   Un JSONL con conversaciones instrucción → respuesta.

2. **Configuración LoRA**
   Rango r y capas de atención donde se añaden A y B.

3. **Entrenar**
   SFTTrainer descarga la base, aplica la plantilla de chat y ajusta solo A y B.

4. **Guardar**
   Solo el adaptador: adapter_config.json y adapter_model.safetensors.

Importaciones: datasets, peft y trl. El código completo está en el notebook del ejercicio.

Herramientas para entrenar con LoRA

Herramienta	Qué aporta	Equipo	Cuándo elegirla
Transformers + PEFT + TRL	Ruta estándar en Python sobre PyTorch	GPU NVIDIA, Mac o CPU	Para aprender y para el ejercicio S7
Unsloth	LoRA y QLoRA más rápidos y con menos memoria	GPU NVIDIA	Cuando la GPU se queda corta
MLX-LM	LoRA nativo de Apple	Mac con Apple Silicon	Para entrenar en local en un Mac
Axolotl / LLaMA-Factory	Entrenamiento desde un archivo de configuración	GPU NVIDIA	Para repetir muchos experimentos sin programar
Google Colab / Kaggle	Notebook con GPU en la nube	Navegador	Si tu equipo no tiene GPU