thePower

S8

Modelos cerrados y APIs

Claude, Gemini y OpenRouter
Comparación con modelos abiertos



José Antonio Nuevo

15 y 19 de octubre de 2026 · 18:30–20:00

Tu feedback sobre S7

El QR de AI Engineer evalúa la sesión anterior.

¿Qué pudiste ejecutar?

¿Qué te costó comparar?



Qué cambia en esta sesión

De ejecutar en tu equipo a integrar y comparar servicios.

S7

Elegir y ejecutar en tu equipo

Hardware, Hugging Face y LM Studio

Consultas breves de soporte

S8

Integrar modelos por API

Claude, Gemini y OpenAI

Documentos, código y restricciones

Modelos cerrados por API

Abierto o cerrado depende de los pesos, no de cómo accedemos al modelo.

Abiertos	Se descargan: en local (S7) o remotos por API.
Cerrados	No se distribuyen: solo remoto, por app o API.
Impacto	Pago por uso; el proveedor fija precio, versiones y datos.

Un modelo de pesos abiertos servido por OpenRouter es remoto y va por API, pero sigue siendo abierto.

Claude, Gemini y OpenAI



Claude

Anthropic

Fable / Opus
Sonnet / Haiku

Haiku: rapidez.
Sonnet: equilibrio.
Opus / Fable: capacidad.



Gemini

Google

Pro / Flash
Flash-Lite

Flash-Lite: eficiencia.
Flash: equilibrio.
Pro: tareas complejas.



GPT

OpenAI

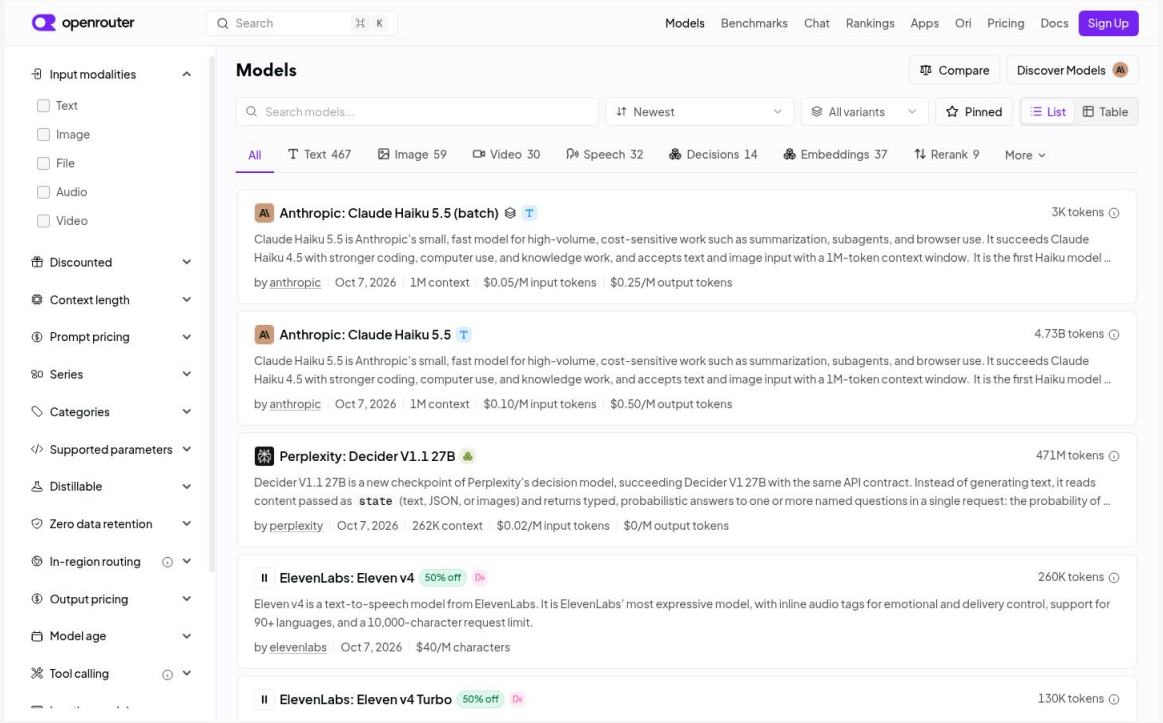
Astra / Sol / Luna

Luna: volumen y coste.
Sol: equilibrio.
Astra: tareas complejas.

Proveedor → familia → ID concreto en la llamada. ChatGPT es una aplicación, no un modelo.

Tres rutas para pedir una respuesta

Interfaz común o API del proveedor.



OpenRouter

Interfaz común

Gemini

API nativa de Google

Claude

Messages API

OpenRouter no es una familia de modelos: une proveedores en una interfaz, pero no iguala sus funciones.

Qué enviamos y qué comprobamos

Aplicación → petición → API del proveedor → modelo → respuesta.

Petición

Endpoint y API key
ID del modelo
Instrucciones y mensajes
Límite de salida

Respuesta

Bloques de texto
Motivo de parada
Tokens usados
Latencia y coste

Primera prueba: «Responde exactamente: API lista.» Comprueba la integración, no la calidad.

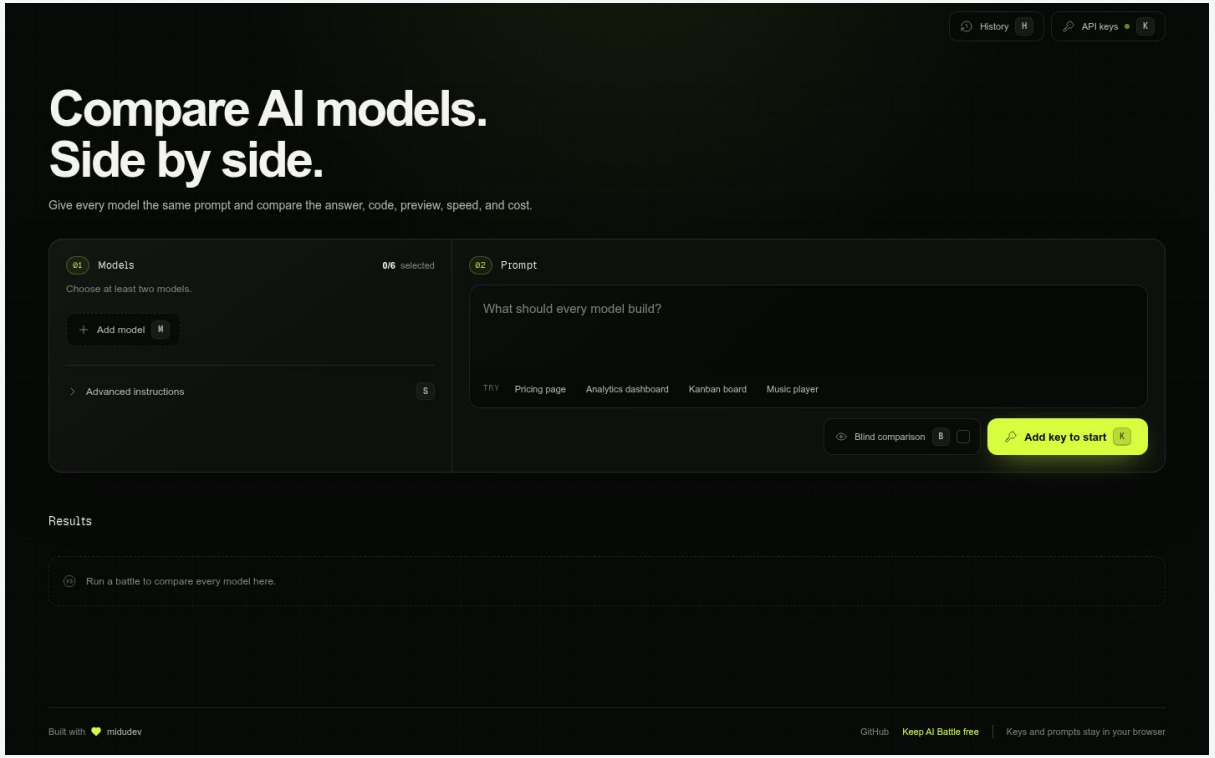
Misma llamada, tres estructuras

Lo que veremos en el terminal: mismos elementos, distinto nombre y lugar.

	Claude · Messages	Gemini · nativa	OpenRouter
Endpoint	`/v1/messages`	`models/{id}:generateContent`	`/api/v1/chat/completions`
Clave	`x-api-key`	`x-goog-api-key`	`Authorization: Bearer`
Modelo	`model`	en la URL	`model: proveedor/modelo`
Instrucciones	`system`	`systemInstruction`	`mensaje role: system`
Entrada	`messages`	`contents → parts`	`messages`
Límite	`max_tokens (obligatorio)`	`maxOutputTokens`	`max_tokens`
Texto	`content[].text`	`candidates → parts → text`	`choices → message`
Consumo	`usage`	`usageMetadata`	`usage`
Parada	`stop_reason`	`finishReason`	`finish_reason`
Errores	`401 · 429 · 529`	`400 · 403 · 429`	`401 · 402 · 429`

Volvemos a isbetter.ai

Un modelo abierto por API, Gemini y Claude.



Leer a ciegas

Puntuar con evidencias

Revelar los modelos

El voto necesita una prueba

Calidad por tarea; después rapidez, coste y datos. Abierto, cerrado o híbrido.

Tarea	Prueba observable
Dossier	Citas, hechos, contradicciones, nada inventado
Código	Pruebas del contrato superadas
Plan	Restricciones cumplidas y sumas correctas

Ganador, empate o ninguna válida: no es un benchmark.

Fine-tuning gestionado: qué cambia

Gemini: ajuste gestionado en Google Cloud.
Claude: referencia con prompting, sin ajustar.

Prompt	Definimos lo que debe hacer el modelo en cada consulta.
Few-shot	Añadimos ejemplos al contexto, sin entrenar el modelo.
Ajuste	El modelo aprende de datos mediante un trabajo de ajuste.

Dataset → trabajo de ajuste → modelo ajustado → endpoint → evaluación. Los pesos no se descargan.