Sesión 10 · RAG

Chatbot con RAG completo

Enunciado

Construye un chatbot que responda usando una colección de documentos. Debe recuperar información, generar una respuesta basada en ella y mostrar las fuentes. Cuando los documentos no permitan contestar, deberá indicarlo de forma explícita.

Explicación completa del ejercicio

Trabajo obligatorio. Prepara al menos ocho documentos ficticios en Markdown o TXT. Implementa lectura, limpieza, división en fragmentos, embeddings, almacenamiento, búsqueda y generación. Basta un notebook, terminal o API; no se pide frontend ni despliegue.

Configura los modelos y la base de datos. Usa como referencia Gemini 3.8 Flash, Gemini Embedding 2 y PostgreSQL con pgvector. Guarda los modelos en `GEN_MODEL_ID` y `EMBEDDING_MODEL_ID`. Para esta práctica fija la salida del embedding en 768 dimensiones y crea una columna `vector(768)` con índice HNSW. Usa el mismo modelo y dimensión para documentos y consultas, y registra las versiones.

Conserva las fuentes. Da un identificador estable a cada documento y fragmento. Al responder, muestra qué fragmentos respaldan la respuesta. Trata su contenido como datos: un texto dentro del documento no debe cambiar las instrucciones del chatbot.

Decide cuándo rechazar una pregunta. Implementa un control antes de generar, por ejemplo un umbral de similitud. Explica qué puntuación utilizas, cuándo aceptas un fragmento y cómo elegiste el umbral. Si usas una distancia, recuerda que un valor menor indica mayor proximidad. No basta con escribir «si no sabes, dilo» en el prompt.

Separa calibración y prueba. Elige el umbral con ejemplos de validación distintos del test. Después, evalúa 20 preguntas reservadas: 14 con respuesta en el corpus y seis sin ella. Escribe la respuesta esperada o el motivo de rechazo antes de ejecutar el sistema y no cambies las reglas usando esos resultados.

Guarda evidencias. Para cada pregunta conserva los fragmentos recuperados, sus puntuaciones, la respuesta y sus fuentes. Registra cuántas de las 14 preguntas respondibles se resuelven correctamente y cuántas de las seis no respondibles se rechazan. Identifica la versión de documentos, preguntas y configuración para comparaciones posteriores. Es una muestra de laboratorio, no una prueba definitiva de calidad.

Ampliación opcional. Añade lectura de PDF o una interfaz visual. No cambies el conjunto de prueba para que el resultado parezca mejor.

Entrega y valoración. Entrega código de ingesta y consulta, documentos sintéticos, configuración de la base de datos, resultados y README. Se valorarán el flujo completo, las fuentes comprobables, el rechazo explícito y la separación entre calibración y evaluación. No incluyas documentos privados ni credenciales.

Dedicación orientativa: 4–6 horas activas con PostgreSQL y acceso a los modelos preparados.