Sesión 11 · RAG avanzado

Construir un CRAG completo desde cero

Enunciado

Implementa un Corrective RAG que recupere información, reordene los resultados y corrija la búsqueda cuando la evidencia no baste para responder. Entrega un proyecto que pueda ejecutarse desde documentos en bruto y un índice vacío, sin depender de un servicio de otra práctica.

Explicación completa del ejercicio

Usa al menos ocho documentos ficticios breves. Implementa ingesta, fragmentación, embeddings y búsqueda en PostgreSQL con pgvector. Define identificadores para documentos y fragmentos y mantén iguales el modelo y la dimensión de embeddings al indexar y consultar. Configura los modelos por variables de entorno. No uses una plantilla que entregue el CRAG ya resuelto.

Construye el grafo. Con LangGraph separa recuperación, reranking, valoración de evidencia, reformulación y respuesta o rechazo. Puedes usar Qwen3-Reranker-0.6B siguiendo su formato de entrada oficial. Recupera hasta diez candidatos y reordénalos antes de seleccionar el contexto. Explica la escala de sus puntuaciones; no son una garantía de que la pregunta esté resuelta.

Distingue tres situaciones. Define umbrales y comprueba qué parte de la pregunta cubren los fragmentos. Con evidencia suficiente, responde. Si es ambigua, conserva los fragmentos útiles, reformula y combina la información nueva sin duplicados. Si es insuficiente, descarta el contexto rechazado y vuelve a recuperar con una consulta reformulada. No utilices las respuestas del test para tomar estas decisiones.

Limita la corrección. Permite como máximo dos reformulaciones después de la búsqueda inicial: tres recuperaciones internas en total. Si sigue faltando evidencia, rechaza la pregunta. Registra consultas, puntuaciones, fragmentos conservados y descartados y ruta final. Muestra un caso de cada ruta y un rechazo; utiliza pruebas controladas para verificar también el límite.

Compara RAG y CRAG. Incluye en el mismo proyecto una referencia de recuperación y respuesta sin corrección. Evalúa ambos sobre 20 preguntas nuevas, 14 respondibles y seis sin respuesta. Mantén corpus, modelo, instrucciones y parámetros comunes. Ajusta umbrales solo con ejemplos de validación distintos y congela la configuración antes del test.

Mide sin ocultar errores. Informa respuestas correctas sobre las 14 respondibles y rechazos correctos sobre las seis restantes, mostrando numerador y denominador. Añade recuperaciones medias y latencia. Revisa manualmente si las fuentes respaldan las respuestas y conserva los fallos. No se exige Ragas ni demostrar que CRAG siempre mejora; la muestra es pequeña.

Ampliación opcional. Añade búsqueda en documentación pública como último recurso, con fuentes y un límite propio. No la uses para inventar políticas internas que falten en el corpus.

Entrega y valoración. Entrega código completo, datos ficticios, instrucciones para reconstruir el índice, grafo, trazas y comparación. Se valorarán las tres rutas diferenciadas, los límites, las fuentes verificables y una evaluación bajo las mismas condiciones.

Dedicación orientativa: 6–8 horas activas con entorno de modelos y base de datos preparado.

Documentación de apoyo: Qwen3-Reranker-0.6B · pgvector · LangGraph