Sesión 12 · Deep Research + Multimodal

Grafo de chatbot multimodal con memoria, herramientas y capacidad de deep research

Enunciado

Construye un asistente con LangGraph que interprete una imagen y un audio, recuerde la conversación, consulte una herramienta propia y realice una investigación. Una respuesta breve también debe poder escucharse mediante text-to-speech (TTS).

Explicación completa del ejercicio

Trabajo obligatorio. Usa un único caso ficticio, por ejemplo una consulta de soporte con una captura de error y una nota de voz. Basta un notebook o una terminal. No necesitas interfaz web, voz en tiempo real ni varios agentes.

Procesa las entradas y genera voz. Usa Gemini 3.8 Flash como referencia para comprender una imagen sintética y un audio de hasta 30 segundos; este puede ser sintetizado. Demuestra una respuesta que utilice información de ambos. Convierte una respuesta de hasta tres frases a audio con Gemini 3.8 Flash-Lite TTS. Configura `MULTIMODAL_MODEL_ID` y `TTS_MODEL_ID`; no uses datos privados.

Conserva la memoria. Utiliza un checkpointer, que guarda el estado del grafo entre turnos, y un `thread_id` distinto por conversación. Demuestra dos conversaciones sin mezclar sus datos. Guarda el texto extraído y las referencias a los archivos, no imágenes o audios binarios ni base64 dentro del estado.

Añade una herramienta pequeña. Por ejemplo, consultar en un diccionario el estado de un ticket ficticio. Debe ser de solo lectura y validar sus argumentos. El grafo distinguirá cuándo responder directamente, usar la herramienta o iniciar una investigación.

Integra la investigación asíncrona. Usa Gemini Deep Research mediante la Interactions API; configura `DEEP_RESEARCH_AGENT_ID`, con `deep-research-preview-04-2026` como referencia. Esta integración usa `GEMINI_API_KEY` de Gemini API, no las credenciales de Google Cloud empleadas para el tuning.

Controla la espera. Un nodo inicia la tarea con `background=True` y guarda el `interaction_id`; otro consulta su estado con un número y tiempo máximos de intentos. Al volver a consultar usa ese mismo identificador, sin crear otra investigación. Maneja finalización, fallo y espera agotada. Dejar de consultar no significa que la tarea remota se haya cancelado.

Limita el consumo. Ejecuta una sola investigación real dentro del presupuesto del laboratorio. Guarda el resultado y las fuentes y reutilízalos en la demo, indicando que se trata de una ejecución anterior. Puedes simular fallos para probar su manejo, pero no sustituir con una simulación la investigación real.

Ampliación opcional. Procesa PDF o sustituye el bucle de consulta por una interrupción y reanudación del grafo. No se exige streaming ni varias voces.

Entrega y valoración. Entrega código, entradas ficticias, audio de salida y evidencias de memoria separada, herramienta e investigación. Se valorarán la comprensión de imagen y audio, la voz, el aislamiento de conversaciones y los límites de ejecución.

Dedicación orientativa: 6–9 horas activas con entorno y credenciales preparados, sin contar la espera remota.