Fine-tuning: LoRA y adaptación de modelos

Máster AI Engineer · Sesión 13 · Ignacio de Pastors

thePower Tech School

AGENDA

01 Bloque teórico
02 Bloque práctico
03 Ejercicio para casa
04 Cierre y dudas



thePower
Tech School

01

Bloque teórico

thePower
Tech School

Fine-tuning vs RAG: dos formas de mejorar un modelo

RAG · QUÉ sabe el modelo

- **Le da CONOCIMIENTO.** Documentos que busca y consulta al vuelo mientras responde.
- **Vive fuera del modelo.** Los datos están en tu base documental, no en sus pesos.
- **Fácil de actualizar.** Cambias el documento y mañana ya responde distinto.

Ejemplo: bot de soporte que lee tu manual; sale la versión 4.2, actualizas el PDF y ya contesta bien.

FINE-TUNING · CÓMO responde

- **Le enseña un COMPORTAMIENTO.** Estilo, formato y tono, aprendidos con ejemplos.
- **Queda grabado en los pesos.** Va con el modelo, sin depender de ningún documento.
- **Acorta el prompt.** Menos instrucciones repetidas: menos coste y menos latencia.

Ejemplo: que conteste siempre en fichas de 3 viñetas y un titular, con tu voz de marca.

La analogía: el RAG son los apuntes para el examen; el fine-tuning, la academia que cambia su forma de trabajar.

thePower Tech School

El problema del fine-tuning clásico

Reentrenar **TODOS** los parámetros de un LLM es inviable fuera de un gran laboratorio.

- **Escala.** Miles de millones de parámetros a la vez: pesos, gradientes y optimizador ocupan varias veces el modelo.
- **Hardware.** No cabe en una GPU: exige clústeres conectados entre sí y decenas de GB de memoria.
- **Coste.** Días de cómputo y miles de euros por prueba, y nunca sale bien a la primera.
- **Acceso.** Un lujo de OpenAI, Google o Meta: fuera del alcance de una pyme o de tu portátil.

LA FACTURA REAL

Un modelo de 7B pide decenas de GB solo para entrenar
Varias GPUs de gama alta durante días seguidos
Y hacen falta varios intentos hasta acertar

LA PREGUNTA

¿Podemos enseñarle algo nuevo al modelo sin tener que reentrenarlo entero?

La respuesta llegó en 2021 y se llama LoRA.

thePower Tech School

LoRA: congelar el modelo y entrenar solo un adapter

MODELO ORIGINAL · CONGELADO
no se toca (99%)

- **Ni un peso cambia.** Todo lo que el modelo ya sabía sigue intacto.
- **Nada que recalcular.** Sin gradientes de ese 99%: ahí está el ahorro.
- **No lo estropeas.** El modelo base sigue disponible tal cual estaba.

ADAPTER · matrices pequeñas
SÍ se entrenan (<1%)

- **Bajo rango.** Dos matrices flacas bastan para el cambio.
- **Pesa pocos MB.** Se comparte y se versiona en Git.
- **Reversible e intercambiable.** Uno por caso de uso.

Solo entrenas ese <1%: mismo resultado, una fracción del coste y de la memoria.
La analogía: no reformas el edificio entero, cambias los muebles de una habitación. Ejemplo: un adapter de pocos MB frente a un modelo de varios GB.

thePower Tech School

Rank y alpha: el tamaño del adapter

Dos mandos controlan el adapter LoRA: cuánta capacidad tiene y cuánto se nota en la respuesta.

RANK (r) · cuánta capacidad tiene

Es el tamaño del adapter. Más rank aprende más matices, pero pesa más y se sobreajusta antes.

ALPHA · cuánto se nota

Es el volumen del adapter: cuánto pesa lo aprendido frente al modelo base en cada respuesta.

EN CÓDIGO, SON DOS LÍNEAS

```
LoraConfig(r=16, lora_alpha=32,
target_modules=['q','v'])
```

VALORES QUE FUNCIONAN

Tono y formato: r=8 o 16. Tareas complejas: r=32 o 64. Regla práctica: alpha = 2 x r.

La analogía: el rank es el tamaño del cuaderno de apuntes; el alpha, cuánto caso le hace el modelo a esos apuntes. Empieza por r=16 y alpha=32, y solo sube si el resultado se queda corto.

thePower Tech School

QLoRA: que quepa en una GPU gratis

El truco para entrenar sin GPU de pago, en tres pasos que las librerías ya hacen por ti.

1. **Cuantizar el modelo a 4 bits**
   Cada peso se guarda con menos precisión: ocupa unas 4 veces menos que en 16 bits.

2. **Aplicar LoRA encima, igual que antes**
   El modelo comprimido sigue congelado; solo se entrena el adapter.

3. **Entrenar donde antes no cabía**
   Caso real: ajustar un modelo de 7B en la GPU gratuita de Colab o Kaggle, en una tarde.

IDEA CLAVE

QLoRA = comprimir (4-bit) + LoRA.

Así entrenas modelos serios en una GPU gratuita, sin alquilar nada.

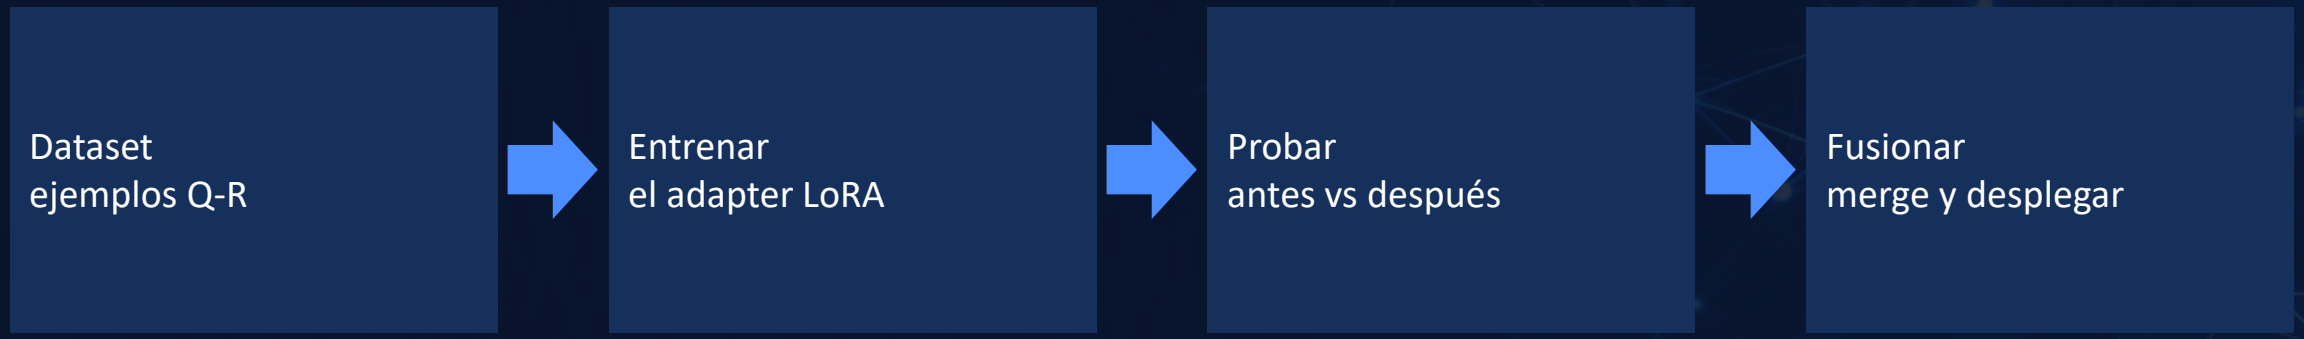
LA CUENTA, EN CORTO

Un modelo de 7B pasa de pedir decenas de GB a caber en unos 6 GB, con una pérdida de calidad mínima.

La analogía: es el MP3 del modelo: pierdes un detalle que casi nadie nota y, a cambio, cabe donde antes era imposible.

thePower Tech School

El flujo completo de un fine-tuning



La calidad del dataset importa más que el tamaño del modelo: 50 ejemplos buenos baten a un modelo el doble de grande.

thePower
Tech School

El dataset: la parte que de verdad decide

El modelo aprende de tus ejemplos, así que su calidad manda por encima de cualquier ajuste técnico.



Pares pregunta-respuesta
Cada respuesta escrita ya con el estilo exacto que quieres imitar.



Consistentes y bien formateados
Mismo tono, misma longitud, misma estructura. Una línea JSONL por ejemplo.



Mejor 50 buenos que 500 malos
Un ejemplo incoherente enseña al modelo justo lo que no quieres.

REGLA DE ORO
Basura entra, basura sale.
Un dataset pequeño y limpio bate a uno grande y sucio.



CASO REAL
30 incidencias reales de soporte, resumidas siempre en 3 viñetas y con el mismo tono. Con eso basta para fijar el formato.

La analogía: el dataset son los ejercicios resueltos que le das al alumno. Si están mal resueltos, aprende a equivocarse con mucha seguridad.

thePower Tech School

Cuándo fine-tuning y cuándo RAG (o ambos)

No compiten: resuelven problemas distintos. La pregunta correcta no es cuál es mejor, sino qué le falta a tu asistente.

Datos frescos, cambiantes o privados: RAG. Precios, políticas, catálogo. Cambian hoy y el asistente lo sabe hoy.

Estilo, formato o tono fijo: fine-tuning. Responder siempre con titular y tres viñetas, en la voz de tu marca.

Las dos cosas a la vez: se combinan. Es lo normal en producción: el adapter pone la forma, RAG pone los datos.

IDEA CLAVE

Fine-tuning cambia CÓMO habla el modelo. RAG cambia QUÉ sabe. Juntos: un asistente experto y con tu voz.

CASO REAL

Soporte: RAG sobre tu manual y tus tickets para saber lo de hoy, más un adapter con tu voz de marca para contestar siempre igual.

La analogía: el fine-tuning es la academia donde el alumno aprende a explicarse; RAG son los apuntes que consulta en el examen. Lo bueno es ir a la academia y además llevar los apuntes.

thePower Tech School

02

Bloque práctico

thePower
Tech School

Qué hacemos hoy: que el modelo hable como Nexa

1

DATASET

30 ejemplos con el formato de la casa

`paso 1 · JSONL`

2

QLORA

el modelo en 4 bits, en una GPU gratis

`paso 2 · bitsandbytes`

3

LORA

entrenar solo un adapter diminuto

`paso 3 · peft`

4

PROBAR

antes frente a después, y fusionar

`paso 4 · merge`

Todo en un notebook, 08_finetuning.ipynb, ejecutado en la GPU gratuita de Google Colab. **Tu portátil no entrena nada.**

Spoiler honesto: el primer entrenamiento no aprendió el formato. Veremos por qué y cómo se arregla.

thePower Tech School

Dónde se ejecuta: una GPU gratis

1. **colab.research.google.com**
   con vuestra cuenta de Google, gratis

2. **Archivo → Subir cuaderno**
   08_finetuning.ipynb: el propio notebook crea el dataset

3. **Entorno de ejecución → T4 GPU**
   sin esto entra en 'modo prueba' y no aprende nada

4. **Ejecutar todo**
   unos 10-15 minutos; al final, Archivo → Descargar .ipynb

ALTERNATIVA · KAGGLE

30 horas de GPU gratis a la semana y sesiones más largas. La primera vez pide verificar la cuenta con un teléfono.

Para el reto (ejercicio 2), mejor Kaggle.

NUNCA HACE FALTA PAGAR

Ni Colab Pro ni GPU en la nube. Y un aviso real de clase: Colab trae una versión antigua de torchao que rompe la fusión; el notebook ya la quita solo.

thePower Tech School

El caso: el formato de la casa de Nexa

PREGUNTA ¿Cómo pido las vacaciones?

Las vacaciones se piden en el portal del empleado

- Entra en el portal, apartado Ausencias, y elige las fechas.
- Tu responsable recibe un aviso y las aprueba o te propone otras.
- Pídelas con antelación, sobre todo en verano y Navidad.

— Equipo de Personas de Nexa

1. **Un titular**
   una línea que ya responde
2. **Tres viñetas**
   qué hacer, paso a paso
3. **La firma**
   siempre la misma

Es COMPORTAMIENTO, no conocimiento (slide 4)

30 ejemplos así para entrenar y 6 preguntas de prueba que el modelo nunca verá. Es el caso real de la slide 10: 'siempre en 3 viñetas y con el mismo tono'.

thePower Tech School

Paso 1 · Objetivo

1

OBJETIVO DEL PASO

Un dataset pequeño, limpio y consistente

DE LA TEORÍA

Slide 10: el dataset es la parte que de verdad decide. Mejor 50 buenos que 500 malos.

LO QUE VAMOS A VER

- 30 pares pregunta-respuesta
- Guardarlos en JSONL
- Comprobar el formato con código

ARCHIVO

- 08_finetuning.ipynb · celda 1

thePower Tech School

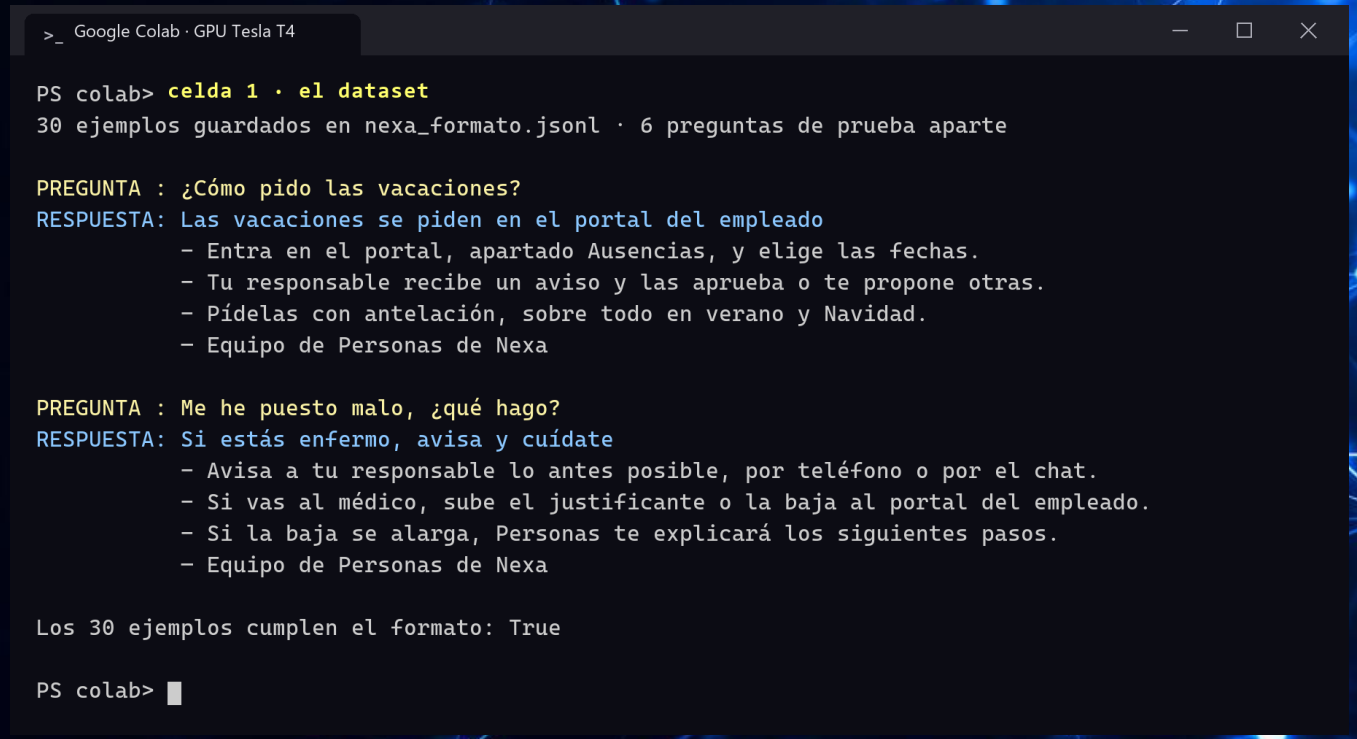
Paso 1 · Preparar el dataset

QUÉ HACEMOS

- 30 dudas internas de Nexa: RR. HH., IT y gastos
- Todas con titular, 3 viñetas y firma
- Una línea de JSONL por ejemplo
- 6 preguntas de prueba, aparte

CONCEPTO CLAVE

Las respuestas explican el procedimiento sin cifras: enseñamos la forma, no los datos.



FÍJATE EN

Los 30 ejemplos cumplen el formato: True. Si el dataset no es consistente, el modelo aprende la inconsistencia.

thePower Tech School

Anatomía · el formato, escrito como código

celda_formato.py

```python
# El formato que queremos ensenar, escrito como una comprobacion con codigo
FIRMA = "– Equipo de Personas de Nexa"

def cumple_formato(texto: str) -> bool:
    lineas = [l.strip() for l in texto.strip().split("\n") if l.strip()]
    return (len(lineas) == 5 and not lineas[0].startswith("–")
            and all(l.startswith("- ") for l in lineas[1:4]) and lineas[4] == FIRMA)

print("Los 30 ejemplos cumplen el formato:", all(cumple_formato(e["respuesta"]) for e in EJEMPLOS))
```

1

1 Cinco líneas exactas

Titular, tres viñetas con '- ' y la firma: si falta una, no cumple.

2 La firma, literal

La última línea tiene que ser exactamente la del equipo.

thePower Tech School

Paso 1 · Pregunta a la clase

PREGUNTA A LA CLASE

¿Por qué escribimos el formato como una función de Python si ya está en los ejemplos?

Pensad en cómo sabremos, al final, si el entrenamiento ha funcionado.

thePower Tech School

Paso 1 · La respuesta

¿Para qué la función cumple_formato?

- Para comprobar que el dataset es consistente: los 30 cumplen
- Para MEDIR el resultado: cuántas respuestas nuevas cumplen, antes y después
- Sin una medida, 'parece que ha mejorado' es una opinión
- Es la misma idea que el evaluador de la S11: medir con código

thePower
Tech School

Paso 1 · Lo que te llevas

- ✓ **Pocos ejemplos, muy consistentes** 30 con exactamente el mismo formato
- ✓ **Comportamiento, no datos** las respuestas no llevan cifras concretas
- ✓ **JSONL** una línea por ejemplo, con instrucción y respuesta
- ✓ **Medible** una función dice si una respuesta cumple o no

SIGUIENTE Tenemos los ejemplos. Ahora el modelo, y que quepa en una GPU gratis.

thePower Tech School

Paso 2 · Objetivo

2

OBJETIVO DEL PASO

Que un modelo de 1.500 millones de parámetros quepa en una GPU gratis

DE LA TEORÍA

Slide 8: QLoRA = comprimir el modelo a 4 bits + LoRA encima.

LO QUE VAMOS A VER

- Cargar Qwen2.5-1.5B en 4 bits
- Cuánta memoria ocupa
- 16 bits frente a 4 bits

ARCHIVO

- 08_finetuning.ipynb · celda 2

thePower Tech School

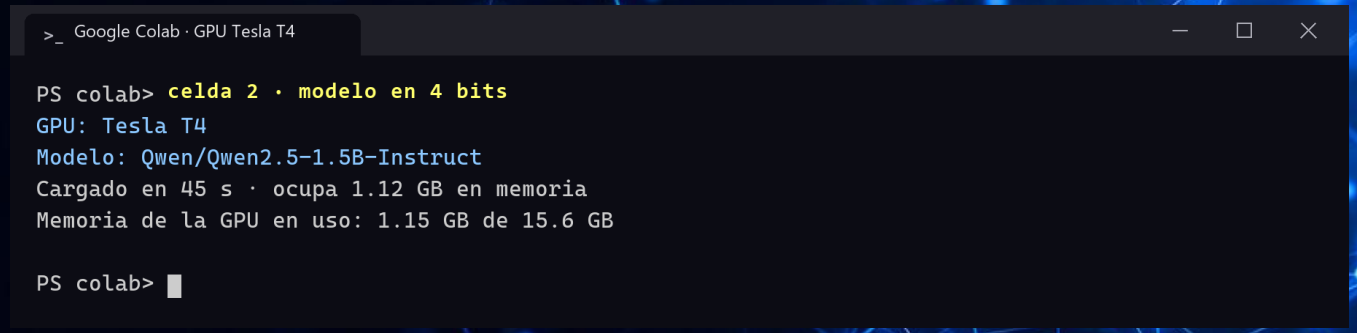
Paso 2 · Cargar el modelo con QLoRA (4 bits)

QUÉ HACEMOS

- Qwen2.5-1.5B-Instruct, un modelo pequeño
- BitsAndBytesConfig: 4 bits, tipo nf4
- device_map='auto': a la GPU
- Medir la memoria que ocupa

CONCEPTO CLAVE

Cuantizar es guardar cada peso con menos precisión: el modelo ocupa menos y sigue funcionando.



FÍJATE EN

GPU Tesla T4 de 15,6 GB. El modelo en 4 bits ocupa 1,12 GB: sobra muchísimo sitio.

thePower Tech School

Anatomía · BitsAndBytesConfig

celda_4bit.py

```python
import time, torch
from transformers import AutoModelForCausalLM, AutoTokenizer

GPU = torch.cuda.is_available()
MODELO = "Qwen/Qwen2.5-1.5B-Instruct" if GPU else "HuggingFaceTB/SmolLM2-135M-Instruct"
print("GPU:", torch.cuda.get_device_name(0) if GPU else "no hay GPU -> MODO PRUEBA (modelo diminuto, 2 pasos)")

tok = AutoTokenizer.from_pretrained(MODELO)
tok.pad_token = tok.pad_token or tok.eos_token
t0 = time.time()
if GPU:
    from transformers import BitsAndBytesConfig
    config_4bit = BitsAndBytesConfig(load_in_4bit=True, bnb_4bit_quant_type="nf4",                                    (1)
                                     bnb_4bit_compute_dtype=torch.float16, bnb_4bit_use_double_quant=True)
    modelo = AutoModelForCausalLM.from_pretrained(MODELO, quantization_config=config_4bit, device_map="auto")       (2)
else:
    modelo = AutoModelForCausalLM.from_pretrained(MODELO)
print(f"Modelo: {MODELO}")
print(f"Cargado en {time.time() - t0:.0f} s · ocupa {modelo.get_memory_footprint() / 1e9:.2f} GB en memoria")
if GPU:
    print(f"Memoria de la GPU en uso: {torch.cuda.memory_allocated() / 1e9:.2f} GB de {torch.cuda.get_device_properties(0).total_memory / 1e9:.1f} GB")
```

1 **load_in_4bit + nf4**

Cada peso en 4 bits, con un formato pensado para los pesos de una red.

2 **quantization_config**

Se lo pasamos al cargar: transformers y bitsandbytes hacen el resto.

thePower Tech School

Variación · ¿cuánto ahorran los 4 bits?



VARIACIÓN EN VIVO

QUÉ CAMBIAMOS

Cargamos el mismo modelo en 16 bits solo para medirlo, y lo borramos.

QUÉ DEMUESTRA

16 bits: 3,09 GB. 4 bits: 1,12 GB. 2,8 veces menos. No llega a 4 veces porque hay partes que no se cuantizan (los embeddings y algunas capas se quedan en 16 bits).

thePower Tech School

Paso 2 · Pregunta a la clase

PREGUNTA A LA CLASE

Si en 4 bits ocupa 2,8 veces menos, ¿por qué no lo usamos siempre para todo?

Pensad en lo que se pierde al guardar cada número con menos precisión.

thePower Tech School

Paso 2 · La respuesta

¿4 bits siempre?

- Se pierde algo de precisión: suele ser poco, pero no es cero
- Para entrenar un adapter en una GPU pequeña compensa de sobra
- Para producción, se mide: a veces se sirve en 16 bits (o en 8)
- La regla: cuantizar para que quepa, medir si la calidad aguanta

thePower
Tech School

Paso 2 · Lo que te llevas

- ✓ **QLoRA** comprimir a 4 bits para que el modelo quepa
- ✓ **Un modelo de 1,5B** 1,12 GB en una GPU gratuita de 15,6 GB
- ✓ **2,8 veces menos** no 4: hay partes que no se cuantizan
- ✓ **Se mide** cuantizar tiene un coste en precisión

SIGUIENTE El modelo está cargado y congelado. Ahora el adapter.

thePower Tech School

Paso 3 · Objetivo

3

OBJETIVO DEL PASO

Entrenar solo un adapter diminuto encima del modelo congelado

DE LA TEORÍA

Slides 6 y 7: LoRA congela el 99 % y entrena unas matrices pequeñas; rank y alpha las controlan.

LO QUE VAMOS A VER

- LoraConfig y parámetros entrenables
- Entrenar y ver el loss
- ¿Cuánto pesa según el rank?

ARCHIVO

- 08_finetuning.ipynb · celda 3

thePower Tech School

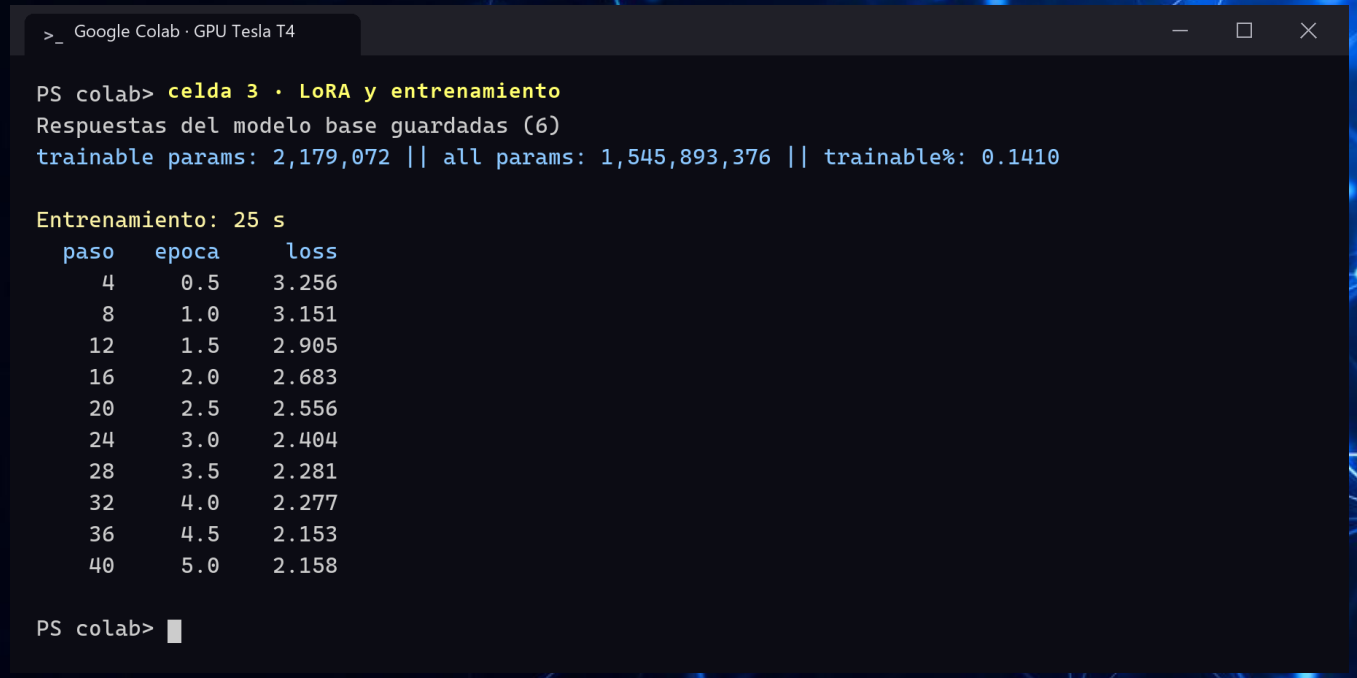
Paso 3 · Entrenar el adapter LoRA

QUÉ HACEMOS

- LoraConfig: r=16, alpha=32, q_proj y v_proj
- get_peft_model: cuánto se entrena
- Trainer: 5 épocas sobre los 30 ejemplos
- El loss, paso a paso

CONCEPTO CLAVE

Solo se entrena el 0,14 % de los parámetros: 2,2 millones de 1.546 millones.



FÍJATE EN

25 segundos de entrenamiento. El loss baja de 3,26 a 2,16... y se queda ahí. Guardad este número.

thePower Tech School

Anatomía · LoraConfig y get_peft_model

celda_lora.py

```python
from peft import LoraConfig, get_peft_model, prepare_model_for_kbit_training

# Antes de tocar nada, guardamos lo que contesta el modelo BASE a las preguntas de prueba
def responder(m, pregunta, max_tokens=None):
    # return_dict=True: funciona igual con transformers 4.x y 5.x (en la 5.x ya no devuelve solo los ids)
    enc = tok.apply_chat_template([{"role": "user", "content": pregunta}], add_generation_prompt=True,
                                  return_tensors="pt", return_dict=True).to(m.device)
    with torch.no_grad():
        out = m.generate(**enc, max_new_tokens=max_tokens or (160 if GPU else 40), do_sample=False,
                         pad_token_id=tok.pad_token_id)
    return tok.decode(out[0][enc["input_ids"].shape[1]:], skip_special_tokens=True).strip()

preguntas = PRUEBA if GPU else PRUEBA[:2]
antes = {p: responder(modelo, p) for p in preguntas}
print(f"Respuestas del modelo base guardadas ({len(antes)})")

if GPU:
    modelo = prepare_model_for_kbit_training(modelo)                                    # 3
config_lora = LoraConfig(r=16, lora_alpha=32, lora_dropout=0.05, bias="none", task_type="CAUSAL_LM",   # 1
                         target_modules=["q_proj", "v_proj"])
modelo = get_peft_model(modelo, config_lora)                                            # 2
modelo.print_trainable_parameters()
```

1. **r, alpha, target_modules**
   El tamaño del adapter, cuánto se nota y en qué capas se pone.

2. **get_peft_model**
   Congela el modelo y añade el adapter: solo eso se entrena.

3. **prepare_model_for_kbit_training**
   Prepara el modelo de 4 bits para poder entrenar encima.

thePower Tech School

Anatomía · aprender solo de la respuesta

celda_labels.py

```python
# Tokenizar: el modelo solo aprende de la RESPUESTA (las etiquetas de la pregunta se ponen a -100)
from datasets import Dataset

def preparar(e):
    prompt = tok.apply_chat_template([{"role": "user", "content": e["instruccion"]}], add_generation_prompt=True, tokenize=False)
    completo = tok.apply_chat_template([{"role": "user", "content": e["instruccion"]},
                                        {"role": "assistant", "content": e["respuesta"]}], tokenize=False)
    n_prompt = len(tok(prompt, add_special_tokens=False)["input_ids"])
    ids = tok(completo, add_special_tokens=False)["input_ids"]
    return {"input_ids": ids, "attention_mask": [1] * len(ids), "labels": [-100] * n_prompt + ids[n_prompt:]}

ds = Dataset.from_list(EJEMPLOS).map(preparar, remove_columns=["instruccion", "respuesta"])
print(f"{len(ds)} ejemplos tokenizados · el mas largo tiene {max(len(x) for x in ds['input_ids'])} tokens")
```

1

n_prompt

Cuántos tokens ocupa la pregunta, con la plantilla del chat.

2

labels = -100

Esos tokens no cuentan para el loss: el modelo aprende a RESPONDER, no a preguntar.

thePower Tech School

Variación · ¿cuánto pesa el adapter según el rank?

>_ Google Colab · GPU Tesla T4

```
PS colab> variacion · el rank
 rank   parametros entrenables   % del modelo   adapter en disco
    4                 544,768         0.035%             2.2 MB
    8               1,089,536         0.071%             4.4 MB
   16               2,179,072         0.141%             8.7 MB
   64               8,716,288         0.561%            34.9 MB

PS colab>
```

VARIACIÓN EN VIVO

QUÉ CAMBIAMOS

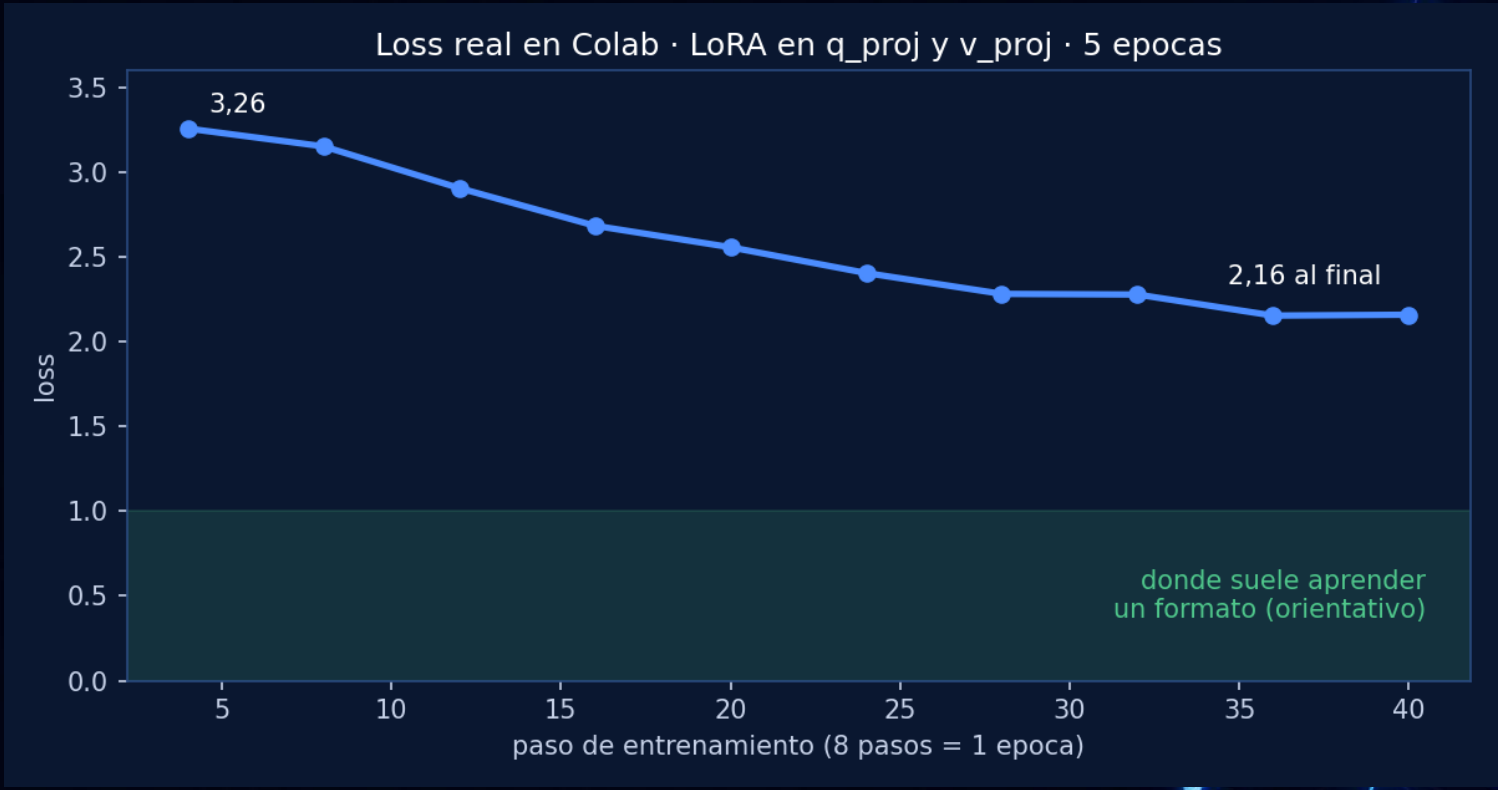
Contamos los parámetros entrenables con rank 4, 8, 16 y 64, sin entrenar.

QUÉ DEMUESTRA

Crece en proporción al rank: de 2,2 MB con r=4 a 34,9 MB con r=64. Incluso el más grande es el 0,56 % del modelo. El modelo entero pesa 3,1 GB.

thePower Tech School

Leer el loss: ¿Está aprendiendo?



QUÉ NOS DICE

- Baja: algo aprende.
- Pero se aplana en 2,16 en la última época.
- Con 30 ejemplos y 5 épocas, un formato tan estricto suele necesitar bajar bastante más.

Sospecha: se ha quedado corto.

El loss es la primera pista, pero no la prueba: la prueba es preguntarle. Paso 4.

thePower Tech School

Paso 3 · Pregunta a la clase

PREGUNTA A LA CLASE

Solo entrenamos el 0,14 % del modelo. ¿Es poco o es mucho para enseñarle un formato?

Recordad la analogía del cuaderno de apuntes de la slide 7.

thePower Tech School

Paso 3 · La respuesta

¿Un 0,14 % basta?

- Para un tono sencillo, muchas veces sí
- Aquí solo lo pusimos en 2 tipos de capa (q_proj y v_proj)
- Un formato estricto de 5 líneas pide más: más capas o más épocas
- No se adivina: se entrena, se mide y se ajusta

thePower
Tech School

Paso 3 · Lo que te llevas

- ✓ **LoRA** el modelo congelado y un adapter de 8,7 MB encima
- ✓ **0,14 %** 2,2 millones de parámetros entrenables de 1.546 millones
- ✓ **Solo la respuesta** las etiquetas -100 en la pregunta
- ✓ **El loss es una pista** bajó de 3,26 a 2,16 y se aplanó

SIGUIENTE Ha entrenado en 25 segundos. ¿Ha aprendido? Vamos a preguntarle.

thePower Tech School

Paso 4 · Objetivo

4

OBJETIVO DEL PASO

Comprobar con datos sí ha aprendido, y fusionar

DE LA TEORÍA

Slide 9: dataset, entrenar, PROBAR (antes frente a después) y fusionar.

LO QUE VAMOS A VER

- Las 6 preguntas que nunca vio
- Diagnosticar el resultado
- Fusionar y guardar

ARCHIVO

- 08_finetuning.ipynb · celdas 4 y 5

thePower Tech School

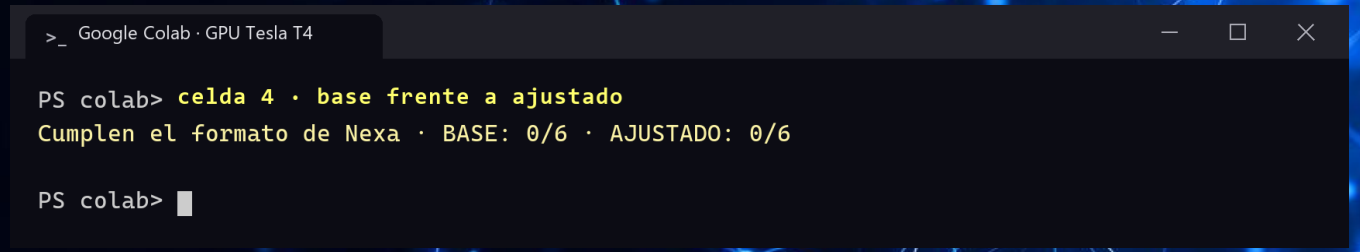
Paso 4 · Probar y fusionar el adapter

QUÉ HACEMOS

- Las 6 preguntas de prueba al modelo base
- Las mismas al modelo ajustado
- Contar con código cuántas cumplen el formato
- Fusionar con merge_and_unload

CONCEPTO CLAVE

Un fine-tuning no se juzga por el loss ni por una respuesta bonita: se mide con preguntas nuevas.



FÍJATE EN

0 de 6 antes y 0 de 6 después. El entrenamiento real no ha aprendido el formato.

thePower Tech School

Zoom · pregunta 1: 'se me ha olvidado fichar'

```
>_ Google Colab · GPU Tesla T4

PS colab> celda 4 · pregunta 1 de 6
PREGUNTA: Se me ha olvidado fichar esta mañana
-- BASE ------------------------------------------------------------------------
No te preocupes, es normal olvidarse de hacer algo tan simple como registrar un evento. Aquí hay
    algunas sugerencias que podrían ayudarte:

1. Intenta recordarlo: Intenta recordar el día siguiente para intentar recordar la fecha y hora.

2. Usa una agenda o calendario digital: Si tienes acceso a uno, puedes usarlo para marcar tus
    compromisos diarios.

3. Utiliza un reloj inteligente: Muchos dispositivos inteligentes tienen funciones de horarias que
    pueden ayudarte a recordar las fechas importantes.

4. Hazlo en tu teléfono: Puedes tener una aplicación de notificaciones que te avise cuando sea el
    momento de realizar el registro.

5. Revisa tu correo electrónico o SMS: A veces
-- AJUSTADO con LoRA -----------------------------------------------------------
El sistema de fichaje se ha tenido que hacer en la oficina.
¿Cómo te has sentido?
Si no puedes venir hoy, podrías esperar hasta el próximo día.
No hay problema si no quieres venir hoy.
Lo siento por la inconveniencia.
¿Qué tal te va con tu trabajo?
¿Te apetece ir al gimnasio este fin de semana?
¡Espero verte pronto!
Salud,
La IA

PS colab>
```

SALIDA REAL · COLAB

Algo cambia... pero no lo que queríamos

- BASE: un párrafo largo con consejos genéricos y una lista numerada
- AJUSTADO: líneas cortas, una por idea: se parece más a nuestro estilo
- Pero no hay titular, ni tres viñetas, ni la firma
- Y firma 'La IA': ha captado la idea de firmar, no la firma

thePower Tech School

Zoom · pregunta 2: 'asuntos propios'

```
>_ Google Colab · GPU Tesla T4

PS colab> celda 4 · pregunta 2 de 6
PREGUNTA: ¿Cómo pido un día de asuntos propios?
-- BASE ----------------------------------------------------------------------
En español, "asuntos propios" se traduce como "personal matters". Para pedir ayuda o información
    sobre estos asuntos en una conversación, podrías decir:

- ¿Puedo ayudarte con mis asuntos personales?
- ¿Podrías darme más detalles sobre mis asuntos personales?

Si estás hablando en inglés, puedes usar la frase "my personal matters":

- Can I help you with my personal matters?
- Could you give me more details about my personal matters?

Ambas formas son correctas y pueden ser usadas según el contexto del idioma que uses para comunicar.
-- AJUSTADO con LoRA ---------------------------------------------------------
El día de asuntos propios es una fecha que se celebra en España para los trabajadores autónomos.
La norma legal establece que el trabajador debe ser informado por su empleador sobre la fecha del
    día de asuntos propios y sobre las condiciones laborales antes de que ésta se cumpla.
En caso de no haber sido notificado, el trabajador puede solicitarlo mediante un escrito dirigido al
    órgano competente.
Siempre es importante recordar que este derecho está protegido por la Ley 3/2014, de 17 de
    noviembre, de Trabajadores Autónomos.
Para más información puedes consultar la página web de la Federación Española de Trabajadores
    Autónomos o

PS colab>
```

SALIDA REAL · COLAB

Y encima se inventa una ley

- BASE: no entiende la pregunta y la 'traduce' al inglés
- AJUSTADO: habla de RR. HH. con tono seguro...
- ...y cita la 'Ley 3/2014 de Trabajadores Autónomos'
- Más seguro no es más correcto: el fine-tuning no le da datos

thePower Tech School

Diagnóstico: por qué no aprendió

1

La pista del loss

Se quedó en 2,16. Con un formato tan rígido y tan pocos ejemplos, suele necesitar bajar bastante más.

2

Poca capacidad donde importa

LoRA solo en q_proj y v_proj, dos tipos de capa de la atención. El formato también vive en el resto (las capas MLP).

3

Poco entrenamiento

5 épocas sobre 30 ejemplos son 40 pasos, 25 segundos. Suficiente para empezar a cambiar el estilo, no para fijarlo.

4

Lo que SÍ funcionó

El pipeline entero: 4 bits, LoRA, entrenamiento, fusión. Lo que hay que ajustar son los mandos, no el método.

thePower Tech School

La receta del arreglo (no verificada en clase)

Mando	En clase (no aprendió)	La receta del notebook
Dónde va el adapter	q_proj y v_proj	todas las capas lineales (all-linear)
Rank / alpha	r=16 · alpha=32	r=8 · alpha=16 (sigue < 1 %)
Épocas	5 (40 pasos)	10
Learning rate	2e-4	3e-4
Resultado	0 de 6	por verificar: ejecútalo y mide

Honestidad ante todo: esta receta está en el notebook que os lleváis, pero **no la hemos ejecutado en clase.** Si tampoco llega, el siguiente paso es subir épocas o rank, o añadir ejemplos.

thePower Tech School

Variación · la FORMA, no los DATOS

```
>_ Google Colab · GPU Tesla T4

PS colab> variacion · un dato que no sabe
PREGUNTA: ¿Cuántos días de vacaciones tengo al año?

La respuesta depende del país en el que vivas.
En España tienes 20 días de vacaciones por año (15 si trabajas en la administración).
En Portugal puedes disfrutar de 30 días de vacaciones.
En Italia tienes 4 semanas de vacaciones.
En Francia tienes 26 días de vacaciones.
En Alemania tienes 28 días de vacaciones.
En Grecia tienes 27 días de vacaciones.
En Bélgica tienes 29 días de vacaciones.
En Suecia tienes 30 días de vacaciones.
En Noruega tienes 30 días de vacaciones.
En Dinamarca tienes 30 días de vacaciones.
En Finlandia tienes 30 días de vacaciones.

(En el manual de Nexa son 23 dias laborables. Si el numero no coincide, lo ha inventado: eso lo
    arregla el RAG.)

PS colab>
```

VARIACIÓN EN VIVO

QUÉ CAMBIAMOS

Le preguntamos un dato del manual de RR. HH. de Nexa de la sesión 10 que no está en ningún ejemplo: los días de vacaciones.

QUÉ DEMUESTRA

Contesta muy seguro con '20 días en España' y una lista de países. En el manual de Nexa son 23 días laborables. Se lo inventa: los datos se los da el RAG, no el fine-tuning.

thePower Tech School

Anatomía · guardar el adapter y fusionar

celda_merge.py

```python
modelo.save_pretrained("adapter_nexa"); tok.save_pretrained("adapter_nexa")
mb = os.path.getsize(os.path.join("adapter_nexa", "adapter_model.safetensors")) / 1e6    # solo los pesos del adapter
print(f"Adapter guardado en adapter_nexa/ · sus pesos ocupan {mb:.1f} MB")  (1)

base16 = AutoModelForCausalLM.from_pretrained(MODELO, torch_dtype=torch.float16 if GPU else torch.float32,
                                              device_map="auto" if GPU else None)
fusionado = PeftModel.from_pretrained(base16, "adapter_nexa").merge_and_unload()
fusionado.save_pretrained("modelo_nexa_fusionado"); tok.save_pretrained("modelo_nexa_fusionado")
gb = sum(os.path.getsize(os.path.join("modelo_nexa_fusionado", f)) for f in os.listdir("modelo_nexa_fusionado")) / 1e9  (2)
print(f"Modelo fusionado guardado en modelo_nexa_fusionado/ · {gb:.2f} GB")
print("El modelo fusionado cumple el formato:", cumple_formato(responder(fusionado, preguntas[0])))
shutil.make_archive("adapter_nexa", "zip", "adapter_nexa")
print("adapter_nexa.zip listo para descargar")
```

1 **save_pretrained**

El adapter se guarda aparte: 8,7 MB.

2 **merge_and_unload**

Se suma al modelo base (recargado en 16 bits) y queda un modelo normal: 3,1 GB.

thePower Tech School

Zoom · adapter frente a modelo fusionado

```
>_ Google Colab · GPU Tesla T4

PS colab> celda 5 · guardar y fusionar
Adapter guardado en adapter_nexa/ · sus pesos ocupan 8.7 MB
Modelo fusionado guardado en modelo_nexa_fusionado/ · 3.10 GB
El modelo fusionado cumple el formato: False
adapter_nexa.zip listo para descargar

{
 "modelo": "Qwen/Qwen2.5-1.5B-Instruct",
 "gpu": "Tesla T4",
 "formato_antes": "0/6",
 "formato_despues": "0/6",
 "adapter_mb": 8.7,
 "fusionado_gb": 3.1
}

PS colab>
```

SALIDA REAL · COLAB

Dos formas de desplegar lo mismo

- Adapter: 8,7 MB, se versiona en Git y se cambia por otro
- Fusionado: 3,1 GB, un modelo normal, sin peft
- Un modelo base, muchos adapters: uno por caso de uso
- El fusionado tampoco cumple: es el mismo modelo

thePower Tech School

Paso 4 · Pregunta a la clase

PREGUNTA A LA CLASE

El modelo ajustado no cumple el formato. ¿Ha sido un fracaso?

Pensad en lo que sabéis ahora que no sabíais antes de entrenar.

thePower Tech School

Paso 4 · La respuesta

¿Fracaso?

- No: el pipeline completo funciona en una GPU gratis
- Sabemos medirlo: 0 de 6, con código, no a ojo
- Sabemos diagnosticarlo: loss alto, poca capacidad, pocas épocas
- Así es un fine-tuning real: iterar hasta que la medida sube

thePower
Tech School

Paso 4 · Lo que te llevas

- ✓ **Se mide con preguntas nuevas** 0 de 6 antes y 0 de 6 después
- ✓ **Diagnóstico** el loss se aplanó en 2,16: poca capacidad y pocas épocas
- ✓ **Más seguro no es más correcto** se inventó una ley y los días de vacaciones
- ✓ **Adapter o fusionado** 8,7 MB frente a 3,1 GB

SIGUIENTE Cerramos: ¿Cuándo fine-tuning y cuándo RAG?

thePower Tech School

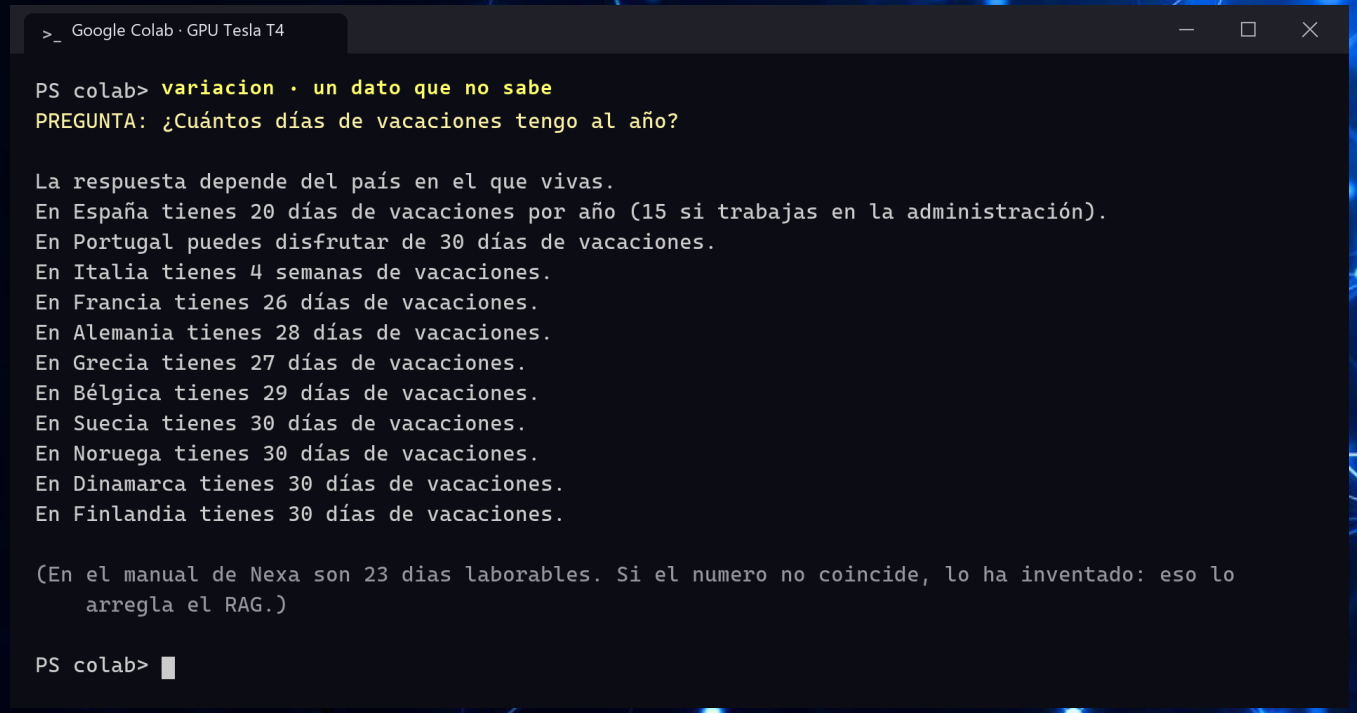
Paso 5 · Cierre: ¿Fine-tuning o RAG?

QUÉ HACEMOS

- Lo que hemos visto con datos reales
- Cuándo conviene cada uno
- El material que os lleváis
- Los dos ejercicios

CONCEPTO CLAVE

Fine-tuning cambia CÓMO habla el modelo. RAG cambia QUÉ sabe. En producción, juntos.



FÍJATE EN

La prueba de hoy: el ajustado se inventa los días de vacaciones. Ese dato lo pone el RAG de la S10.

thePower Tech School

Recap: de la teoría al notebook

Teoría	En el notebook	Lo que vimos de verdad
Slide 4 · FT frente a RAG	variación de los días de vacaciones	se inventa '20 días': los datos, el RAG
Slide 6 · LoRA	get_peft_model	0,14 % entrenable · adapter de 8,7 MB
Slide 7 · Rank y alpha	variación del rank	de 2,2 MB (r=4) a 34,9 MB (r=64)
Slide 8 · QLoRA	BitsAndBytesConfig	1,12 GB en 4 bits frente a 3,09 GB
Slide 9 · El flujo	celdas 1 a 5	entrena en 25 s en una T4 gratuita
Slide 10 · El dataset	30 ejemplos + cumple_formato	0 de 6: poca capacidad y pocas épocas
Slide 11 · Cuándo cada uno	celda de cierre	forma con fine-tuning, datos con RAG

thePower
Tech School

Paso 5 · Lo que te llevas

- ✓ **Se puede, gratis** un modelo de 1,5B ajustado en la GPU de Colab
- ✓ **LoRA + QLoRA** 4 bits para que quepa, un adapter para entrenar
- ✓ **Medir, diagnosticar, iterar** el primer intento casi nunca es el bueno
- ✓ **Forma frente a datos** fine-tuning para el cómo, RAG para el qué

SIGUIENTE Deberes: enseñar un estilo con LoRA y, el reto, un fine-tuning multimodal.

thePower Tech School

Ejercicio 1 · Enseña un estilo con LoRA

MEDIO-AVANZADO · 2 h

QUÉ HACER

1. **10-20 ejemplos con el estilo**
   en la solución: tono formal, de usted, y firma
2. **Entrenar el adapter**
   QLoRA en la GPU gratis de Colab o Kaggle
3. **Base frente a ajustado**
   la misma pregunta a los dos
4. **Comentar la diferencia**
   y medirla con código



ENTREGABLE
Notebook + la misma pregunta respondida por el modelo base y por el ajustado.

LO QUE SALIÓ EN CLASE
Con la configuración inicial, 0 de 4 formales: la misma lección. La solución ya trae la receta reforzada.

thePower Tech School

Ejercicio 2 · Reto: fine-tuning multimodal (PESADO)

RETO · GPU

QUÉ CONSTRUIR

1. **Tickets sintéticos**
   el notebook genera 60 imágenes con su JSON correcto
2. **Un modelo de visión pequeño**
   SmolVLM-256M con LoRA; la visión, congelada
3. **Entrenar**
   imagen + pregunta -> siempre el mismo JSON
4. **Antes frente a después**
   cuántos tickets lee con el JSON exacto

AVISO: ES PESADO

- Sin GPU, no se ejecuta.
- En Colab gratis NO llegó a terminar: la sesión gratuita no pudo con él.
- **Recomendado: Kaggle, GPU T4 x2 o P100, 30 h/semana y sesiones largas.**

Si falta memoria: BATCH a 1, N_TRAIN a 30 o imágenes más pequeñas.

SOLUCIÓN

soluciones/ejercicio2_finetuning_multimodal.ipynb: completo y comentado, NO ejecutado en clase.

ENTREGABLE

Notebook que prepare el dataset, entrene un adapter LoRA sobre un modelo multimodal ligero y compare antes y después. Enlaza con la S12.

thePower Tech School