thePower

S16 · AI ENGINEER

Cloud deployment: AWS basics

Entender AWS desde su consola: dónde se aloja una API de IA, cómo se le da acceso, cómo se protegen sus claves, cómo se observa y cuánto cuesta.

José Antonio Nuevo



ANTES DE EMPEZAR

Encuesta de S15

Encuesta de la sesión anterior · S15

Formulario de AI Engineer

Valora S15 de tu grupo (no la sesión de hoy).
Escanea el código con la cámara del móvil.

CASO CONDUCTOR

Una API de soporte que consulta un modelo

La misma API nos acompaña toda la sesión. Recibe una incidencia de soporte, llama a un modelo y devuelve una clasificación y una respuesta. La usaremos para dar sentido a cada servicio.

PETICIÓN · POST /clasificar

```
{"texto": "Me han cobrado dos veces la factura de este mes. Es una incidencia ficticia."}
```

↓

Nuestra API

FastAPI dentro de un contenedor Docker · GET /health · POST /clasificar

↔

Modelo

Proveedor externo por HTTPS (Anthropic en la referencia de S16)

↓

RESPUESTA · forma del JSON (valores ilustrativos)

```
{"resultado": {"categoria": "facturacion",
               "prioridad": "alta | media | baja",
               "respuesta": "…"},
 "metadata":  {"request_id": "…", "execution": "real",
               "version": "…", "duration_ms": …,
               "consumo": {"input_tokens": …}}}
```

La metadata la añade el servidor: el modelo no puede inventarla.

QUÉ NECESITAMOS EN AWS PARA…



Alojarla — ECS + Fargate (o EC2)

Un lugar donde corra el contenedor; con Fargate no administramos servidores.



Darle acceso — VPC + security group

Una red con ruta a Internet y una regla que solo deja entrar a quien autorizamos.



Proteger sus claves — Secrets Manager + IAM

La clave del proveedor vive fuera de la imagen; solo un rol concreto puede leerla.



Observarla — CloudWatch

Una línea de log por petición con request_id, estado y duración; métricas y alarmas.



Controlar el gasto — Billing, Budgets y calculadora

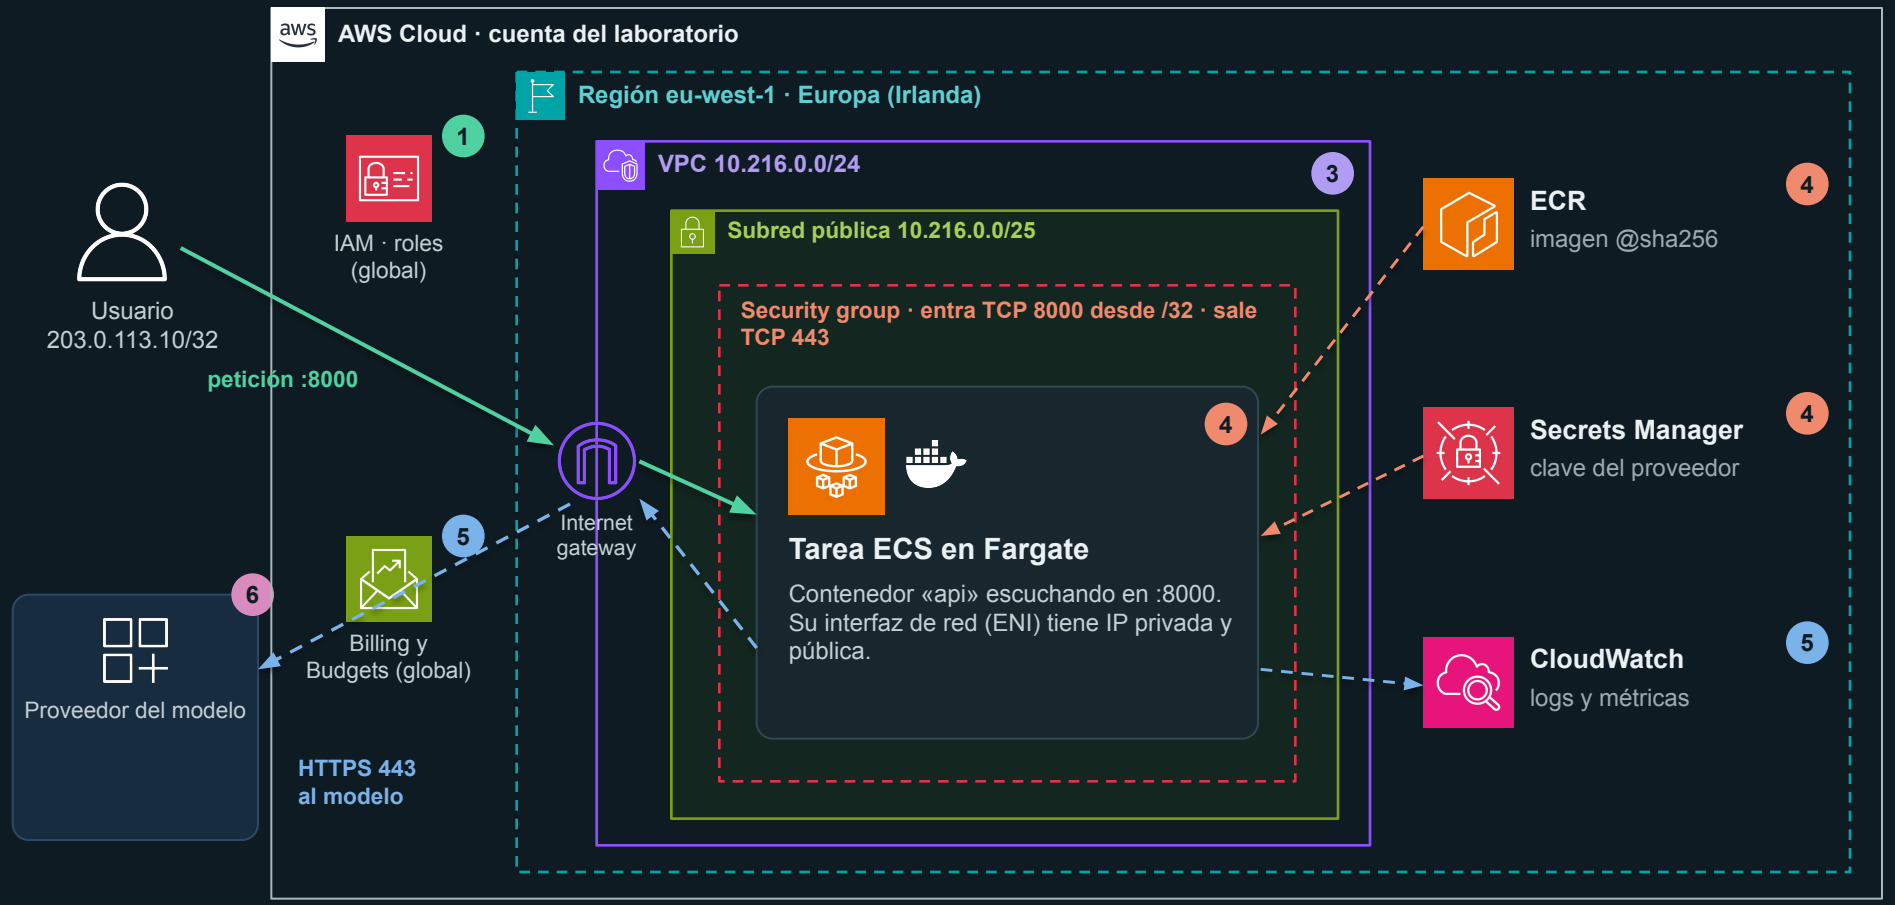
Estimar antes de crear, vigilar mientras existe y retirar al terminar.

IDEA GUÍA El problema de IA ya lo conocemos de S7/S8. Hoy cambia dónde se ejecuta, quién puede usarlo y cuánto cuesta mantenerlo.

EL MAPA DE LA SESIÓN

Las piezas de AWS alrededor de nuestra API

Cada bloque explica una parte de este diagrama. Al final podremos seguir una petición de izquierda a derecha y nombrar el servicio que interviene en cada paso.



DÓNDE LO EXPLICAMOS

1. Cuenta, región, ARN e IAM
2. EC2 + EBS como alternativa; S3 si guardáramos adjuntos
3. VPC, subred, ruta, gateway y security group
4. Docker, ECR, ECS, Fargate y secretos
5. CloudWatch, Billing y Budgets
6. Bedrock frente a un proveedor externo

IDEA Alojar, conectar, proteger, observar y pagar: cada servicio de hoy responde a una de esas cinco necesidades.

Los servicios esenciales de AWS, agrupados por función

AWS ofrece más de doscientos servicios, pero casi cualquier aplicación se construye con unas pocas piezas. Las agrupamos por la pregunta que responden. En verde, las que usa hoy nuestra API.

CÓMPUTO · dónde se ejecuta el código



Amazon EC2
Máquinas virtuales: elegimos tamaño y administramos el SO.



AWS Lambda
Funciones que se ejecutan por evento; pago por uso.

CONTENEDORES · empaquetar y orquestar



Amazon ECR · hoy
Registro privado de imágenes de contenedor.



Amazon ECS / EKS · hoy
Orquestadores: ECS es el de AWS; EKS, Kubernetes.



AWS Fargate · hoy
Ejecuta contenedores sin servidores que administrar.

ALMACENAMIENTO · dónde guardo archivos



Amazon S3
Objetos (archivos) por API, con durabilidad muy alta.



Amazon EBS
Discos de bloques para instancias EC2.



Amazon EFS
Sistema de archivos NFS compartido entre instancias.

BASES DE DATOS · dónde guardo registros



Amazon RDS / Aurora
Bases relacionales SQL gestionadas: PostgreSQL, MySQL…



Amazon DynamoDB
NoSQL clave-valor, sin servidores, en milisegundos.

RED Y ENTREGA · cómo llega el tráfico



Amazon VPC · hoy
Red privada: subredes, rutas y security groups.



Elastic Load Balancing
Reparte el tráfico entre destinos sanos.



Route 53 · CloudFront
DNS y red de entrega de contenido (CDN).

SEGURIDAD · quién accede y qué se protege



AWS IAM · hoy
Identidades y permisos: quién hace qué sobre qué.



Secrets Manager · hoy
Claves y contraseñas cifradas, fuera del código.



AWS KMS
Claves de cifrado gestionadas y auditables.

OPERACIÓN Y COSTE · qué pasa y cuánto



Amazon CloudWatch · hoy
Logs, métricas y alarmas de los recursos.



AWS CloudTrail
Registro de cada llamada a la API: quién hizo qué.



Budgets · Cost Explorer · hoy
Presupuestos, alertas y análisis del gasto.

INTELIGENCIA ARTIFICIAL · modelos



Amazon Bedrock
Modelos fundacionales de varios proveedores por API.



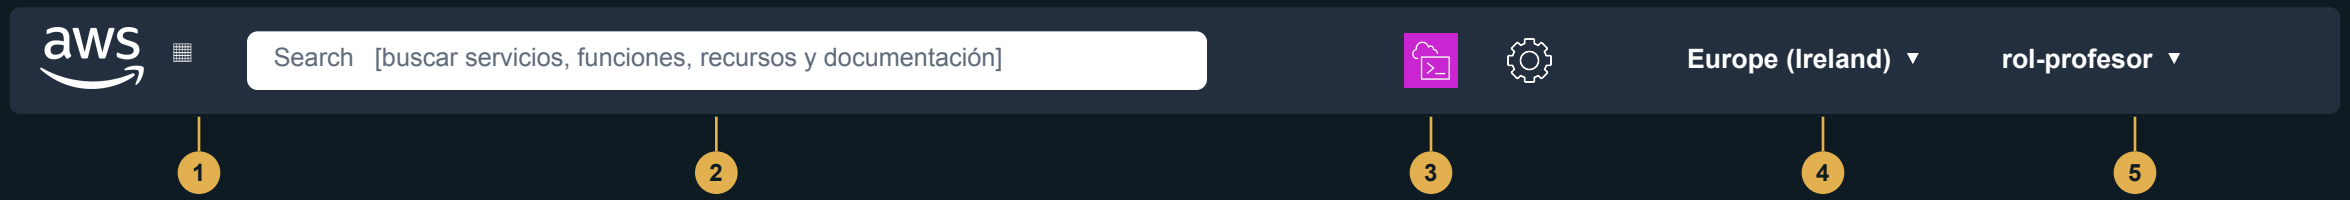
Amazon SageMaker AI
Entrenar, ajustar y desplegar modelos propios.

IDEA GUÍA No hace falta conocer los doscientos servicios: con cómputo, datos, red, seguridad y observación se construye casi todo.

Dónde estamos: servicio, región y cuenta

La barra superior se mantiene en todos los servicios. Antes de interpretar una pantalla comprobamos tres datos: en qué servicio estamos, qué región está seleccionada y con qué identidad hemos entrado.

ESQUEMA · no es una captura



1 Menú de servicios

Catálogo por categorías, favoritos y servicios visitados recientemente.

2 Buscador

Escribir «ECS», «bucket» o «budgets» lleva al servicio, a sus funciones y a la documentación.

3 CloudShell

Terminal en el navegador con las credenciales de la sesión.

4 Región

Cambia lo que vemos en los servicios regionales. En IAM o Billing indica «Global».

5 Cuenta e identidad

Usuario o rol con el que hemos entrado, ID de la cuenta y acceso a Billing.

RECORRIDO QUE HAREMOS EN CADA SERVICIO

Buscar el servicio → **Comprobar región** → **Abrir el listado** → **Abrir un recurso o formulario** → **Cancel**

Cuenta vacía: los listados muestran que no hay recursos y ofrecen el botón «Create…». Basta para explicar columnas, filtros y las opciones del formulario. Los servicios regionales muestran solo lo que existe en la región seleccionada.

IDEA GUÍA Si un recurso «ha desaparecido», mira primero la región y la cuenta: la mayoría de los listados son regionales.

Región, zona de disponibilidad y alcance global

Una región es una ubicación geográfica con varias zonas de disponibilidad aisladas entre sí. La región condiciona la latencia, los servicios y modelos disponibles, las tarifas y dónde quedan los datos.



Repartir réplicas entre zonas da disponibilidad; una tarea única no. Las letras a, b y c se asignan por cuenta: el ID de zona (por ejemplo euw1-az1) identifica la zona física.

REGIONALES · cambian con el selector

- EC2 y EBS
- VPC
- ECS y Fargate
- ECR
- Secrets Manager
- CloudWatch
- Bedrock

GLOBALES · la consola indica «Global»

- IAM
- Billing and Cost Management

CASO ESPECIAL · S3

La consola lista todos los buckets de la cuenta, pero cada bucket vive en la región elegida al crearlo y sus objetos no salen de ella salvo que los copiemos.

IDEA GUÍA Elegimos región por usuarios, datos, servicios, modelos y precio. Cambiarla después implica recrear recursos.

RESPONSABILIDAD COMPARTIDA

Qué protege AWS y qué seguimos protegiendo nosotros

AWS responde de la seguridad «de» la nube; el cliente responde de la seguridad «en» la nube. El reparto cambia según el servicio que elegimos.

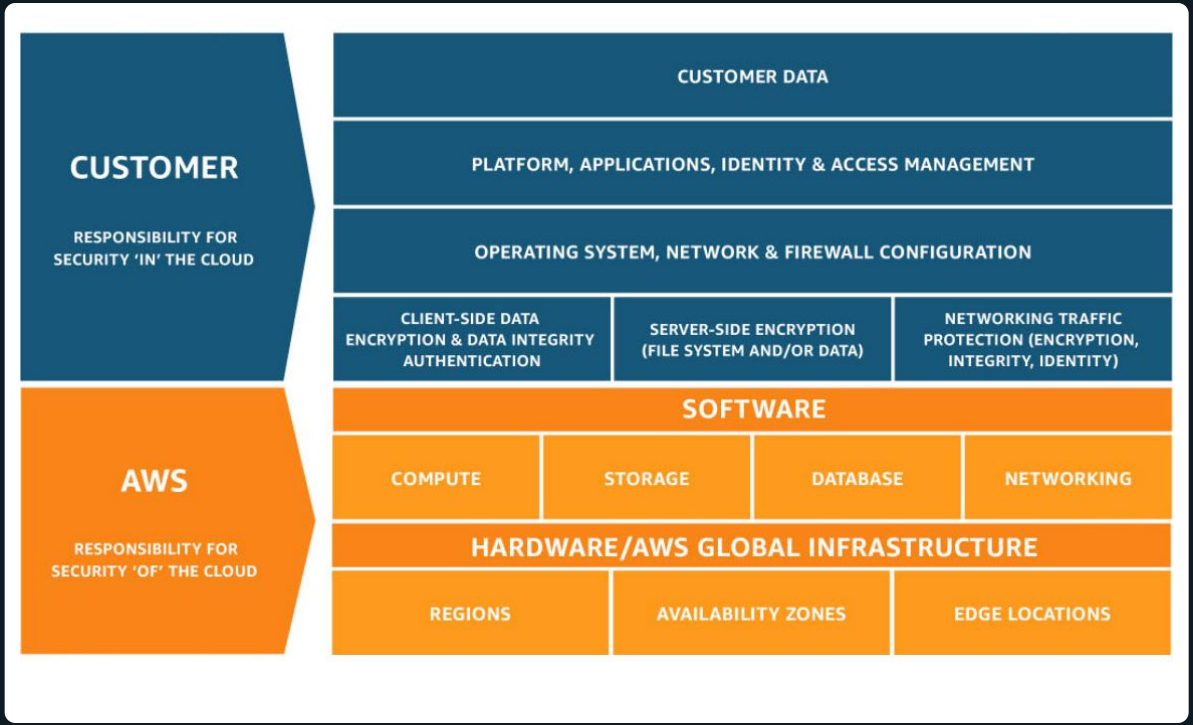


Imagen oficial de AWS (en inglés). CUSTOMER: cliente, seguridad «en» la nube. AWS: seguridad «de» la nube, desde el hardware hasta las regiones, zonas y ubicaciones de borde.

	EC2	ECS en Fargate	Bedrock
AWS GESTIONA	Hardware, red física y virtualización.	Además, el host, su sistema operativo y el agente de contenedores.	La infraestructura y la ejecución del modelo.
GESTIONAMOS NOSOTROS	Sistema operativo y parches, Docker, aplicación, security groups, IAM, datos y claves.	Imagen y dependencias, definición de tarea, roles, red y security groups, secretos y datos.	Permisos IAM, datos que enviamos, prompts, cuotas, coste y validación de respuestas.

En S16 elegimos Fargate: AWS mantiene el host; nosotros reconstruimos y volvemos a publicar la imagen cuando cambian sus dependencias.

IDEA GUÍA Fargate nos quita los servidores, no las decisiones: imagen, permisos, red, secretos y datos siguen siendo nuestros.

IAM: quién puede hacer qué sobre qué recurso

Cada llamada a la API de AWS la hace una identidad. IAM evalúa las políticas que le aplican y decide si esa acción está permitida sobre ese recurso. Si nada lo permite, se deniega.

Identidad

Usuario, grupo o rol. ECS usa roles con credenciales temporales.

Política

Documento JSON con efecto, acciones, recursos y condiciones.

Acción

servicio:operación, por ejemplo secretsmanager:GetSecretValue.

Recurso

El ARN concreto sobre el que se actúa: un secreto, un bucket…

POLÍTICA DE EJEMPLO · lectura de un único secreto

```
{
  "Version": "2012-10-17",
  "Statement": [{
    "Effect": "Allow",
    "Action": "secretsmanager:GetSecretValue",
    "Resource": "arn:aws:secretsmanager:eu-west-1:
      111122223333:secret:s16-lab/anthropic-AbCdEf"
  }]
}
```

1 · **Effect** Allow o Deny. 2 · **Action** servicio:operación. 3 · **Resource** un ARN concreto, no «*». **Un Deny explícito gana siempre.**

EN LA CONSOLA

`IAM › Roles › (rol) › Permissions | Trust relationships`

- Permissions: políticas adjuntas y su JSON.
- Trust relationships: quién puede asumir el rol, p. ej. ecs-tasks.amazonaws.com.
- Cuenta nueva: suele haber roles vinculados a servicios que sirven para enseñar las pestañas.
- IAM es global: el selector de región indica «Global».

IDEA GUÍA Una política responde a tres preguntas: qué acción, sobre qué recurso y con qué efecto.

CUENTA DE AWS

Antes de crear nada: proteger la cuenta y acotar el gasto

La cuenta es la frontera de seguridad y de facturación. El usuario root lo puede todo y no se limita con políticas de IAM, así que se protege y se guarda. El trabajo diario se hace con otras identidades y con un presupuesto vigilando.

1

Proteger el usuario root

Activa MFA en el usuario root, no crees claves de acceso para él y úsalo solo para las pocas tareas que lo exigen, como cambiar el plan de soporte o cerrar la cuenta.

2

Trabajar con otra identidad

Entra con un usuario de IAM Identity Center o asume un rol con credenciales temporales. Concede solo los permisos que la tarea necesita: es el principio de mínimo privilegio.

3

Crear un presupuesto

En AWS Budgets, define un importe mensual con avisos por correo, por ejemplo al 50 %, 80 % y 100 %. El aviso llega, pero no detiene ningún recurso.

4

Etiquetar y retirar

Etiqueta cada recurso (Project, Owner) para encontrarlo en Cost Explorer y bórralo al terminar la práctica. Lo que existe, cobra, aunque nadie lo use.

CUENTAS NUEVAS DESDE JULIO DE 2025 · PLAN GRATUITO O PLAN DE PAGO

Al registrarse se reciben 100 USD en créditos y se pueden ganar otros 100 USD completando actividades guiadas, como lanzar y terminar una instancia EC2 o crear un presupuesto. Los créditos caducan a los 12 meses.

Con el plan gratuito la cuenta no genera cargos, pero se cierra a los 6 meses o al agotar los créditos si no pasamos al plan de pago, y algunos servicios solo están disponibles en el plan de pago.

IDEA GUÍA Primero MFA y presupuesto; después, los recursos. Una alerta avisa: solo borrar recursos detiene el gasto.

EC2: un servidor virtual que alquilamos por segundos

Amazon Elastic Compute Cloud (EC2) es uno de los primeros servicios de AWS y la base de muchos otros. Nos da capacidad de cómputo (CPU, memoria, red y disco) en forma de máquinas virtuales llamadas instancias.

Elastic · elástico

Creamos una instancia en minutos, cambiamos su tamaño o lanzamos cien iguales, y las eliminamos cuando ya no hacen falta. Pagamos mientras están en marcha, sin comprar hardware ni pagar por adelantado.

Compute · cómputo

Cada instancia recibe vCPU, memoria y ancho de red según su tipo. Dentro instalamos lo que queramos: Linux o Windows, Docker, una base de datos o nuestra API de IA.

Cloud · nube

El hardware está en los centros de datos de AWS. Nosotros elegimos la región y la zona de disponibilidad; AWS elige el servidor físico concreto en el que arranca la instancia.

La analogía

Es como alquilar un ordenador en un centro de datos: AWS pone el edificio, la energía, la red y el hardware; nosotros decidimos qué se instala, cómo se configura y quién puede entrar.

LO QUE ELEGIMOS Y ADMINISTRAMOS



Cada instancia está aislada de las demás aunque compartan el mismo hardware.

AWS Nitro System · virtualización y aislamiento por hardware

Servidor físico (host)
en un centro de datos de la zona eu-west-1a

LO QUE OPERA AWS: hardware, hipervisor, red física, energía y refrigeración

Facturación por segundo · mín. 60 s

Recurso regional · vive en una zona

IDEA GUÍA EC2 es la pieza de cómputo más flexible de AWS: lo que ganamos en control lo pagamos en administración.

EC2: una máquina virtual que administramos

Una instancia EC2 es un servidor virtual. AWS opera el hardware; nosotros elegimos imagen, tamaño y red, y administramos el sistema operativo y todo lo que instalamos encima.

AMI (imagen de la máquina)

Plantilla con sistema operativo y software inicial. Fija la arquitectura: x86_64 o arm64 (Graviton).

Tipo de instancia

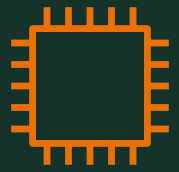
Familia y tamaño: vCPU y memoria. t3.small = 2 vCPU y 2 GiB; t4g.small es su equivalente arm64.

Volumen EBS raíz

El disco del sistema. Persiste aunque detengamos la instancia, y se sigue cobrando.

Red

VPC, subred, security group e IP pública opcional: deciden quién puede conectar.



Instancia EC2

AMI
Amazon Linux 2023 · x86_64

TIPO
t3.small · 2 vCPU · 2 GiB

DISCO
EBS gp3 · 8 GiB

RED
subred · SG · IP pública

ROL
instance profile (opcional)

LO QUE NOS CORRESPONDE

- Parches del sistema operativo y del runtime.
- Instalar Docker y arrancar la API, también tras un reinicio.
- Escalado, alta disponibilidad y copias de seguridad.
- Acceso seguro: claves SSH o Session Manager con un rol.

CUÁNDO TIENE SENTIDO

Control total del sistema, GPU, software que no cabe en un contenedor gestionado o cargas siempre encendidas.

COSTE Segundos en marcha (Linux, mínimo 60 s) + GB de EBS aprovisionados aunque esté detenida + IPv4 pública por hora.

IDEA GUÍA Con EC2 alquilamos una máquina; con Fargate, la ejecución de un contenedor. Cambia lo que administramos.

Cómo leer un tipo de instancia: serie, generación, opciones y tamaño

El nombre del tipo de instancia resume el hardware que recibimos. Si sabemos leerlo, no hace falta memorizar el catálogo: primero elegimos la familia según la carga y después el tamaño según la demanda.



- **SERIE** c = optimizada para cómputo: más CPU por cada GiB de memoria.
- **GENERACIÓN** 7 = séptima. Cuanto más alta, más reciente.
- **OPCIONES** g = procesador AWS Graviton (Arm) · n = red y EBS optimizados.
- **TAMAÑO** 4xlarge = 16 vCPU y 32 GiB. Cada salto de tamaño suele duplicar vCPU y memoria.

EJEMPLOS PARA PRACTICAR LA LECTURA

`t3.small`	uso general ampliable · 2 vCPU · 2 GiB · laboratorios
`m7g.large`	uso general · Graviton · 2 vCPU · 8 GiB
`r7i.2xlarge`	memoria · Intel · 8 vCPU · 64 GiB · bases de datos
`g6.xlarge`	GPU NVIDIA L4 · 4 vCPU · 16 GiB · inferencia de IA

USO GENERAL

M · T

Equilibrio entre CPU y memoria. Las T acumulan créditos y pueden superar su rendimiento base durante un tiempo: APIs con poco tráfico, pruebas y laboratorios.

CÓMPUTO

C

Más CPU por GiB de memoria. Servidores web con mucho tráfico, procesamiento por lotes, codificación de vídeo y simulación.

MEMORIA

R · X · U

Más memoria por vCPU. Bases de datos, cachés en memoria y análisis de grandes volúmenes de datos.

ACELERADAS

P · G · Inf · Trn

GPU de NVIDIA o chips de AWS: Inferentia para inferencia y Trainium para entrenamiento. Aquí viven los modelos de IA propios.

ALMACENAMIENTO

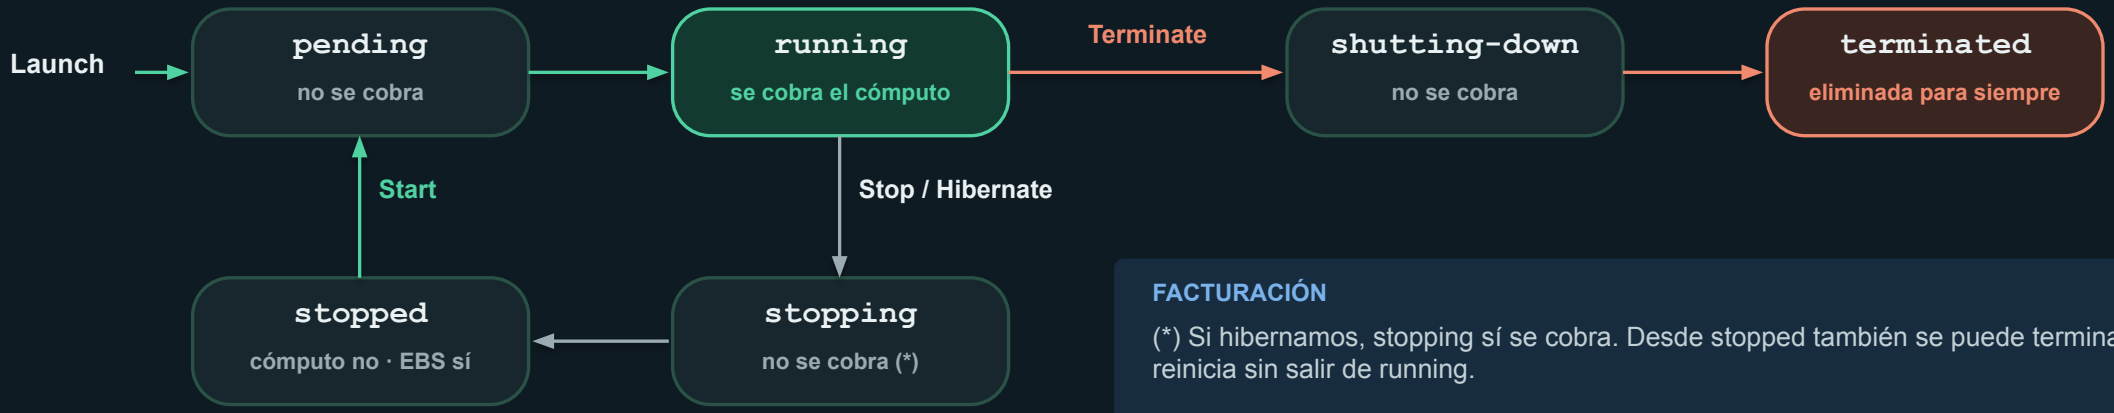
I · D

Discos NVMe locales muy rápidos (instance store). Bases de datos de alto rendimiento y sistemas distribuidos.

IDEA GUÍA Empezamos pequeño, medimos con CloudWatch y ajustamos. Cambiar de tipo es detener, elegir otro tipo y volver a arrancar.

Ciclo de vida: qué pasa y qué se cobra en cada estado

Una instancia pasa por varios estados desde que la lanzamos hasta que la eliminamos. El cómputo solo se cobra en running, pero los volúmenes EBS, las Elastic IP y los snapshots siguen costando mientras existan.



FACTURACIÓN

(*) Si hibernamos, stopping sí se cobra. Desde stopped también se puede terminar. Reboot reinicia sin salir de running.

REBOOT · reiniciar

Reinicia el sistema operativo. La instancia sigue en el mismo servidor físico y conserva sus IP. Se pierde lo que estaba en memoria. Útil después de instalar parches.

STOP / START · apagar

Apaga sin borrar: el volumen EBS se conserva (y se cobra). La IP pública automática se libera y al arrancar recibe otra; para fijarla, una Elastic IP. Puede volver en otro servidor y se pierde el instance store.

HIBERNATE · hibernar

Variante de stop que guarda el contenido de la memoria RAM en el volumen EBS raíz. Al arrancar, los procesos continúan donde estaban. Hay que habilitarla al lanzar la instancia.

TERMINATE · eliminar

Borra la instancia sin vuelta atrás. El volumen raíz se elimina si tiene «Delete on termination» activado (por defecto, sí). En instancias importantes, activa la protección contra terminación.

IDEA GUÍA Detener no es borrar: lo que sigue existiendo (disco, Elastic IP, snapshots) sigue cobrando.

Entrar y arrancar: claves, Session Manager, user data y metadatos

Una instancia recién lanzada es un servidor vacío. Necesitamos una forma segura de entrar, un modo de instalar el software sin hacerlo a mano y una manera de que la aplicación obtenga credenciales sin guardarlas en disco.



Key pair y SSH

AWS coloca la clave pública en la instancia y nosotros guardamos la privada (.pem). Exige abrir el puerto 22 en el security group, idealmente solo para nuestra IP. Si perdemos la clave privada, AWS no puede recuperarla.



Session Manager

Forma parte de AWS Systems Manager. Abre una terminal desde la consola o la CLI sin puertos de entrada ni claves SSH: decide IAM y cada sesión puede quedar registrada. Requiere el agente de SSM (ya incluido en Amazon Linux) y un rol.



User data

Un script que la instancia ejecuta en su primer arranque (con cloud-init en Linux). Lo usamos para instalar Docker, descargar la imagen y arrancar la API. Así la instancia se puede recrear idéntica tantas veces como haga falta.



Metadatos e instance profile

Desde dentro, la dirección 169.254.169.254 informa del ID, la región y las credenciales temporales del rol asociado (instance profile). Los SDK de AWS las recogen solos. Usamos IMDSv2, que exige un token de sesión.

USER DATA DE EJEMPLO · AMAZON LINUX 2023

```
#!/bin/bash
# Se ejecuta una vez, en el primer arranque
dnf install -y docker
systemctl enable --now docker

REG=111122223333.dkr.ecr.eu-west-1.amazonaws.com
aws ecr get-login-password --region eu-west-1 \
  | docker login -u AWS --password-stdin $REG

docker run -d --restart always \
  -p 8000:8000 $REG/s16-api:1.0
```

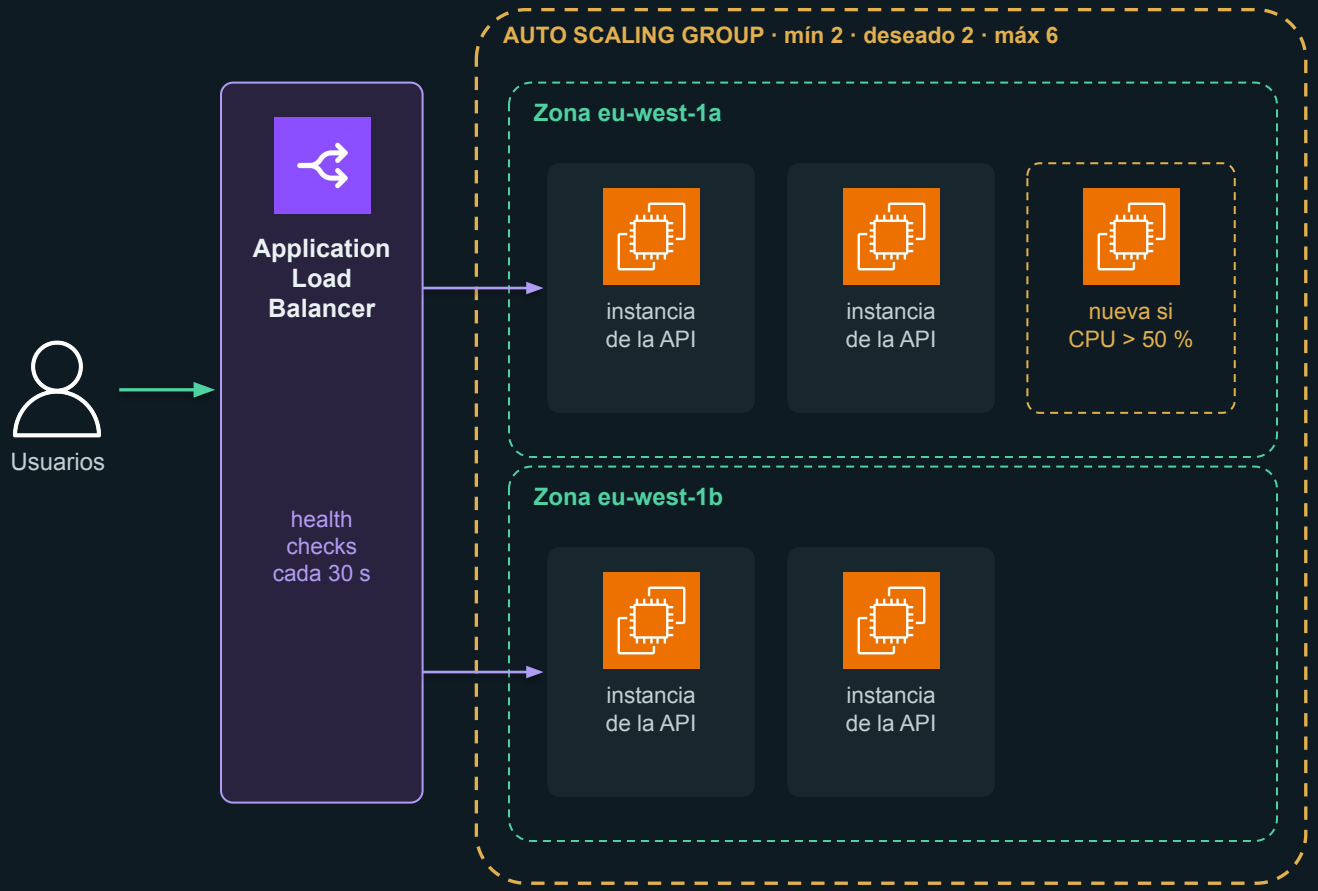
El rol de la instancia da permiso para leer de ECR: no hay claves en el script.

--restart always vuelve a levantar la API tras un reinicio. La clave del modelo se leería de Secrets Manager con ese mismo rol.

IDEA GUÍA En producción no se entra a la máquina a configurarla: se describe en user data o en una AMI propia y se recrea.

De una instancia a una flota: plantilla, Auto Scaling y balanceador

Una sola instancia es un punto único de fallo: si cae su servidor o su zona, cae la API. Para tolerar fallos y crecer, repetimos la misma instancia en varias zonas y ponemos un balanceador delante.



1 AMI propia

Imagen con el sistema y nuestro software ya instalados. Arranca más rápido y más igual que instalarlo todo con user data.

2 Launch template

Receta versionada de la instancia: AMI, tipo, security groups, rol, user data y etiquetas. La usa el Auto Scaling group.

3 Auto Scaling group

Mantiene un número deseado de instancias entre un mínimo y un máximo, sustituye las que fallan y añade o quita según una métrica.

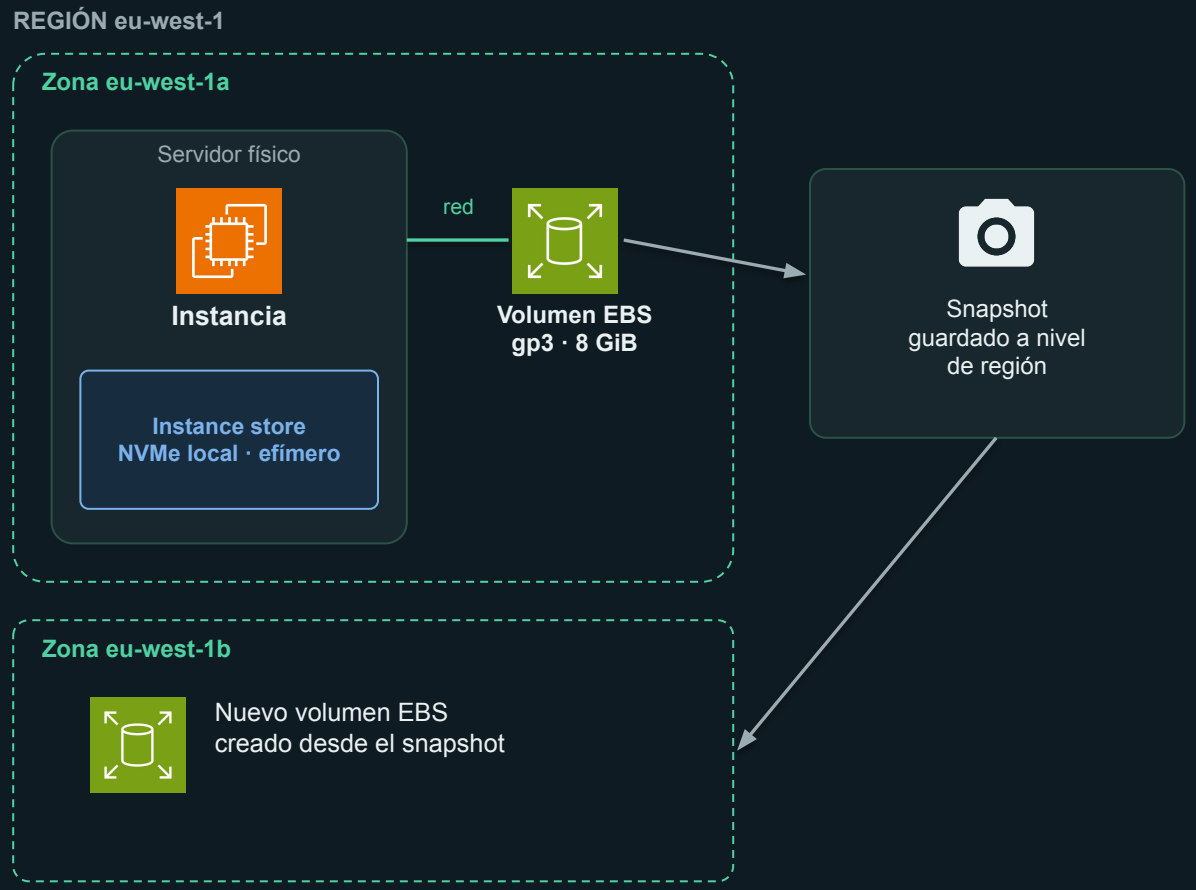
4 Elastic Load Balancing

El Application Load Balancer recibe el tráfico HTTP(S) en un único punto y lo reparte solo entre los destinos que pasan sus health checks.

IDEA GUÍA En la nube se escala en horizontal: más instancias iguales, no una más grande. ECS hace lo mismo con tareas.

Discos de EC2: EBS, snapshots e instance store

Una instancia necesita al menos un disco para su sistema operativo. Elegir bien el almacenamiento decide qué sobrevive a un apagado, cuánto rinde y cuánto cuesta.



AMAZON EBS · el disco habitual

Disco de red persistente que vive en una zona y se conecta a instancias de esa zona. Se amplía sin parar la instancia. gp3 (SSD de uso general) ofrece 3.000 IOPS y 125 MiB/s de base; io2 es para bases de datos exigentes; st1 y sc1 (HDD), para datos secuenciales.

SNAPSHOTS · copias de seguridad

Copias incrementales de un volumen que AWS guarda a nivel de región. Sirven para recuperar datos, crear volúmenes en otra zona y construir AMI. Se automatizan con AWS Backup o Data Lifecycle Manager.

INSTANCE STORE · rápido y efímero

Discos NVMe conectados físicamente al servidor en algunos tipos (con «d» en el nombre). Muy rápidos, pero los datos se pierden al detener o terminar la instancia. Para cachés y datos temporales.

AMAZON EFS · compartido

Si varias instancias necesitan los mismos archivos a la vez, EFS ofrece un sistema de archivos NFS que crece solo.

IDEA GUÍA Lo que importa se guarda fuera de la instancia: en EBS con snapshots, en S3 o en una base de datos.

S3: objetos dentro de buckets

S3 guarda objetos: un archivo con sus metadatos, identificado por una clave dentro de un bucket. Se lee y se escribe por HTTPS con la API; no se monta como el disco de una instancia.



BUCKET

thepower-s16-soporte-ejemplo

`eu-west-1`

CLAVE (KEY) DEL OBJETO	TIPO	TAMAÑO
`adjuntos/2026/11/inc-0142/captura.png`	Imagen	412 KB
`adjuntos/2026/11/inc-0142/nota-voz.m4a`	Audio	1,8 MB
`documentos/politica-reembolsos-v3.pdf`	Documento	236 KB
`datasets/clasificacion/train-2026-10.jsonl`	Dataset	48 MB

Prefijo (en ámbar): parece una carpeta, pero forma parte de la clave.

Objeto = datos + metadatos: tipo de contenido, tamaño, cifrado y versión.

Acceso con la API por HTTPS: PUT, GET, LIST… nunca montando el bucket como un disco.

Región

El bucket vive en una región elegida al crearlo.

Nombre

Único en la partición (por defecto) o en el espacio regional de la cuenta.

Acceso público

Bloqueado por defecto con Block Public Access.

Cifrado

Los objetos nuevos se cifran como mínimo con SSE-S3.

Versionado

Opcional: conserva versiones anteriores de cada objeto.

COSTE GB-mes según la clase de almacenamiento + peticiones + salida a Internet.

IDEA GUÍA S3 no es el disco de una instancia (EBS) ni una base de datos (RDS). En nuestra API guardaría los adjuntos.

Bases de datos gestionadas: RDS, Aurora y DynamoDB

Podríamos instalar una base de datos en EC2, pero tendríamos que parchearla, hacer copias y montar réplicas. Los servicios gestionados se encargan de esa operación; nosotros decidimos el modelo de datos, el tamaño y quién accede.



Amazon RDS y Aurora

relacional · SQL

QUÉ ES

Motores conocidos (PostgreSQL, MySQL, MariaDB, SQL Server, Oracle, Db2) con copias automáticas, parches y Multi-AZ: una réplica en espera en otra zona que toma el relevo si falla la principal. Aurora es el motor de AWS compatible con MySQL y PostgreSQL, con el almacenamiento replicado en tres zonas.

CUÁNDO

Datos con relaciones, consultas SQL flexibles, joins y transacciones.

CÓMO SE PAGA

Horas de instancia de base de datos, GB almacenados y copias de seguridad, según el motor y la configuración.



Amazon DynamoDB

NoSQL · clave-valor y documentos

QUÉ ES

Base de datos sin servidores que administrar. Responde en milisegundos de un dígito a cualquier escala y replica los datos en varias zonas automáticamente. Cada elemento se encuentra por su clave de partición (y, opcionalmente, de ordenación).

CUÁNDO

Accesos que conocemos de antemano: sesiones, carritos, historial por usuario, estado de una petición.

CÓMO SE PAGA

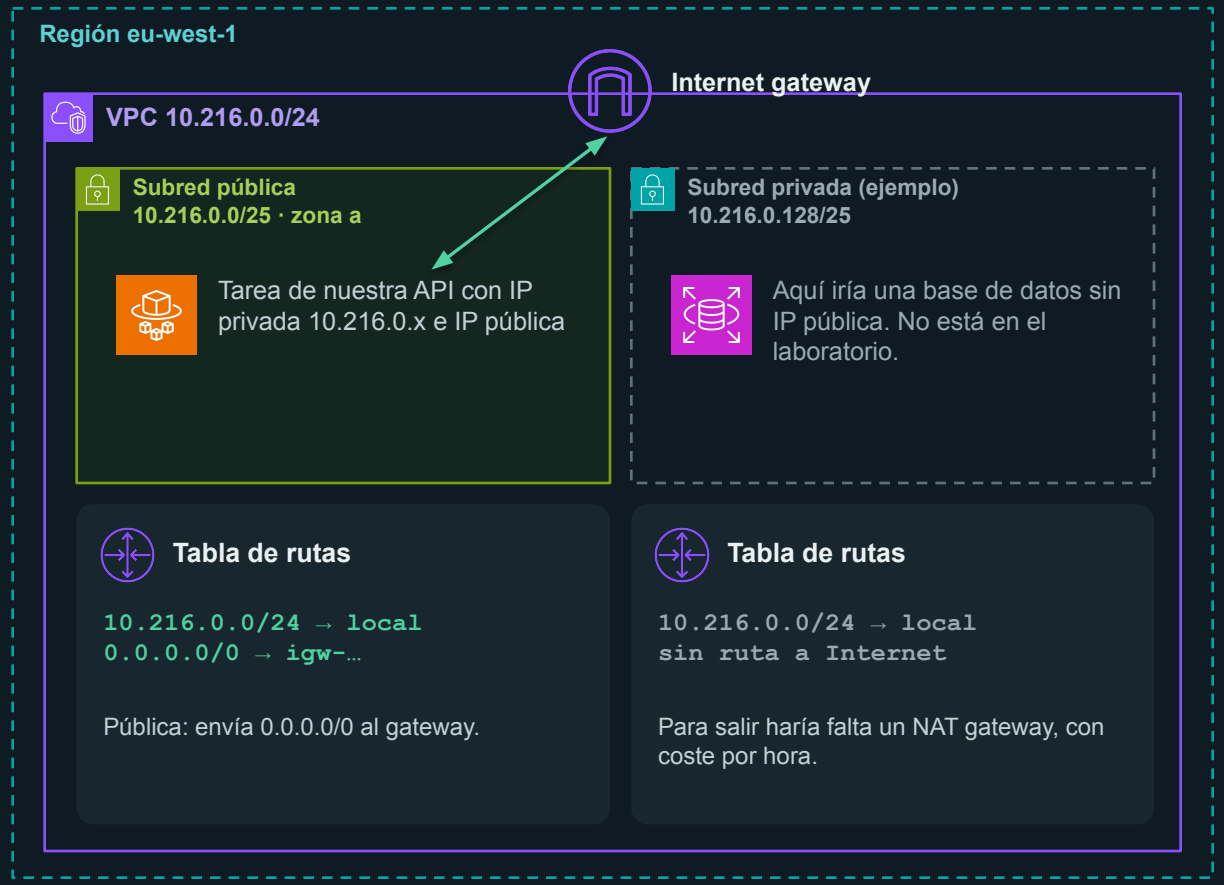
Bajo demanda, por lectura y escritura más GB almacenados; o con capacidad aprovisionada si el tráfico es estable.

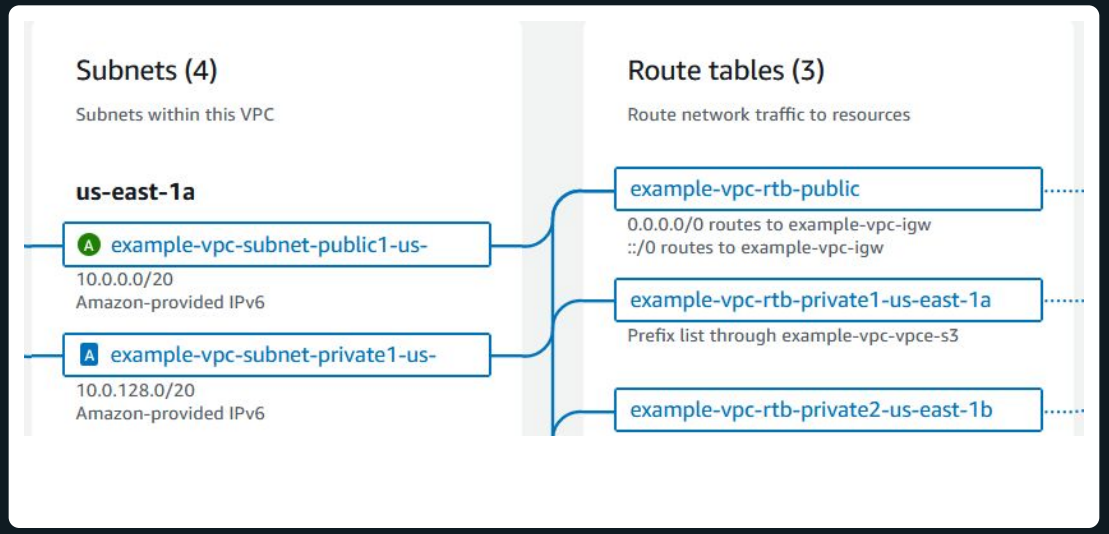
PARA IA PostgreSQL con la extensión pgvector, en RDS o Aurora, guarda embeddings para búsqueda semántica (RAG). Si nuestra API guardara el historial, una tabla DynamoDB por request_id bastaría.

IDEA GUÍA Relacional cuando importan las relaciones y las consultas; DynamoDB cuando conocemos los accesos y queremos escalar sin administrar.

VPC: nuestra red privada dentro de una región

Una VPC es un rango de direcciones privadas que reservamos en una región. Se divide en subredes y cada subred vive en una zona de disponibilidad. Las tablas de rutas deciden adónde va el tráfico.





Resource map de Amazon VPC · captura de la documentación oficial de AWS (ejemplo en us-east-1 con subredes públicas y privadas en dos zonas).

EN LA CONSOLA

`VPC › Your VPCs › (VPC por defecto) › Resource map`

› La VPC por defecto de cada región sirve para enseñarlo sin crear nada.

IDEA GUÍA Una subred es pública por su tabla de rutas, no por su nombre.

RECORRIDO DE UNA PETICIÓN

Tener una IP no basta: cinco condiciones

Una petición desde el portátil del profesor llega al contenedor solo si se cumplen todas las condiciones del recorrido. Si falla una, el síntoma suele ser el mismo: un timeout.



1 IP pública en la ENI

AssignPublicIp=ENABLED en el servicio. Sin ella, la tarea solo tiene IP privada.

2 Gateway conectado

Un internet gateway asociado a la VPC de la tarea.

3 Ruta 0.0.0.0/0 → igw

En la tabla de rutas asociada a la subred de la tarea.

4 Regla de entrada

TCP 8000 desde el /32 del profesor, en el security group de esa ENI.

5 Proceso escuchando

uvicorn en 0.0.0.0:8000 dentro del contenedor, no solo en 127.0.0.1.

VUELTA Y SALIDA

La respuesta vuelve por el mismo camino (el security group tiene estado). Las llamadas al modelo salen por HTTPS 443 por el mismo gateway.

EXPOSE NO ABRE NADA

EXPOSE 8000 en el Dockerfile solo documenta el puerto. En AWS deciden portMappings, el security group, la ruta y la IP pública.

IDEA GUÍA Diagnosticamos siguiendo el recorrido: IP, gateway, ruta, regla y proceso. Abrir todos los puertos solo oculta cuál faltaba.

AMAZON ECR

Docker y ECR: de la imagen local al registro de AWS

Un contenedor empaqueta nuestra API con su runtime y sus dependencias en una imagen inmutable. Para que AWS pueda ejecutarla, primero la publicamos en Amazon ECR, el registro privado de imágenes de nuestra cuenta.



REPOSITORIO

Guarda todas las versiones de una imagen. Es privado, vive en una región y el acceso se concede con IAM. Su dirección incluye cuenta, región y nombre:

`111122223333.dkr.ecr.eu-west-1.amazonaws.com/s16-api`

ETIQUETA Y DIGEST

La etiqueta (1.0, latest) es un nombre que se puede mover a otra imagen; el digest sha256 identifica el contenido exacto. Desplegar por digest, o con etiquetas inmutables, garantiza que se ejecuta lo que probamos.

ESCANEO Y CICLO DE VIDA

ECR puede buscar vulnerabilidades conocidas al subir la imagen y aplicar reglas que borran versiones antiguas. Se paga por GB almacenado y por transferencia de datos fuera de la región.

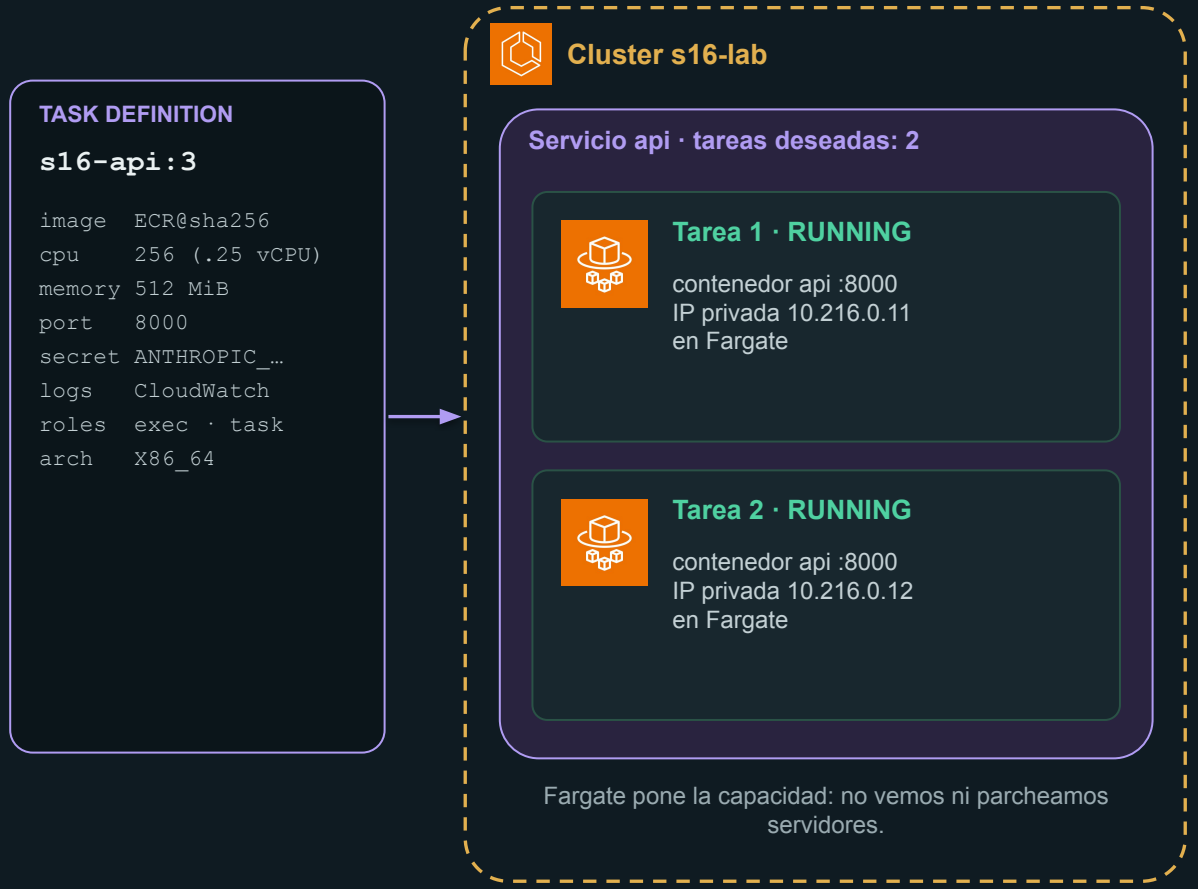
```
docker build --platform linux/amd64 -t s16-api:1.0 .
aws ecr get-login-password --region eu-west-1 | docker login -u AWS --password-stdin $REG
docker tag s16-api:1.0 $REG/s16-api:1.0   &&   docker push $REG/s16-api:1.0
```

En un Mac con Apple Silicon, docker construye arm64 por defecto: --platform evita que la tarea no arranque.

IDEA GUÍA ECR guarda la imagen; no la ejecuta. Quien la ejecuta es ECS, en Fargate o en instancias EC2.

ECS: cluster, definición de tarea, servicio y tarea

Amazon Elastic Container Service (ECS) es el orquestador de contenedores de AWS: decide dónde arrancar cada contenedor, lo vigila y lo sustituye si falla. Con cuatro conceptos se lee toda su consola.



CLUSTER

Agrupación lógica de servicios y tareas en una región. Con Fargate no contiene servidores que administrar; con EC2 agrupa también nuestras instancias.

TASK DEFINITION

Plantilla JSON versionada: imagen, CPU y memoria, puertos, variables, secretos, logs, roles y arquitectura. Cada cambio crea una revisión nueva (s16-api:3, :4…).

TAREA

Una ejecución de la task definition: uno o varios contenedores que arrancan juntos. En Fargate cada tarea tiene su propia interfaz de red y su IP (modo awsvpc).

SERVICIO

Mantiene el número deseado de tareas: si una se detiene, arranca otra. Despliega las revisiones nuevas de forma gradual y puede registrar las tareas en un balanceador.

IDEA GUÍA La task definition dice qué ejecutar; el servicio, cuántas copias mantener; la tarea es lo que está en marcha.

ELEGIR CÓMPUTO

Dónde se ejecuta nuestro código: EC2, ECS con Fargate o Lambda

Las tres opciones ejecutan código; cambian lo que administramos y cómo pagamos. Cuanto más a la derecha, menos operación y menos control. Para nuestra API elegimos Fargate.

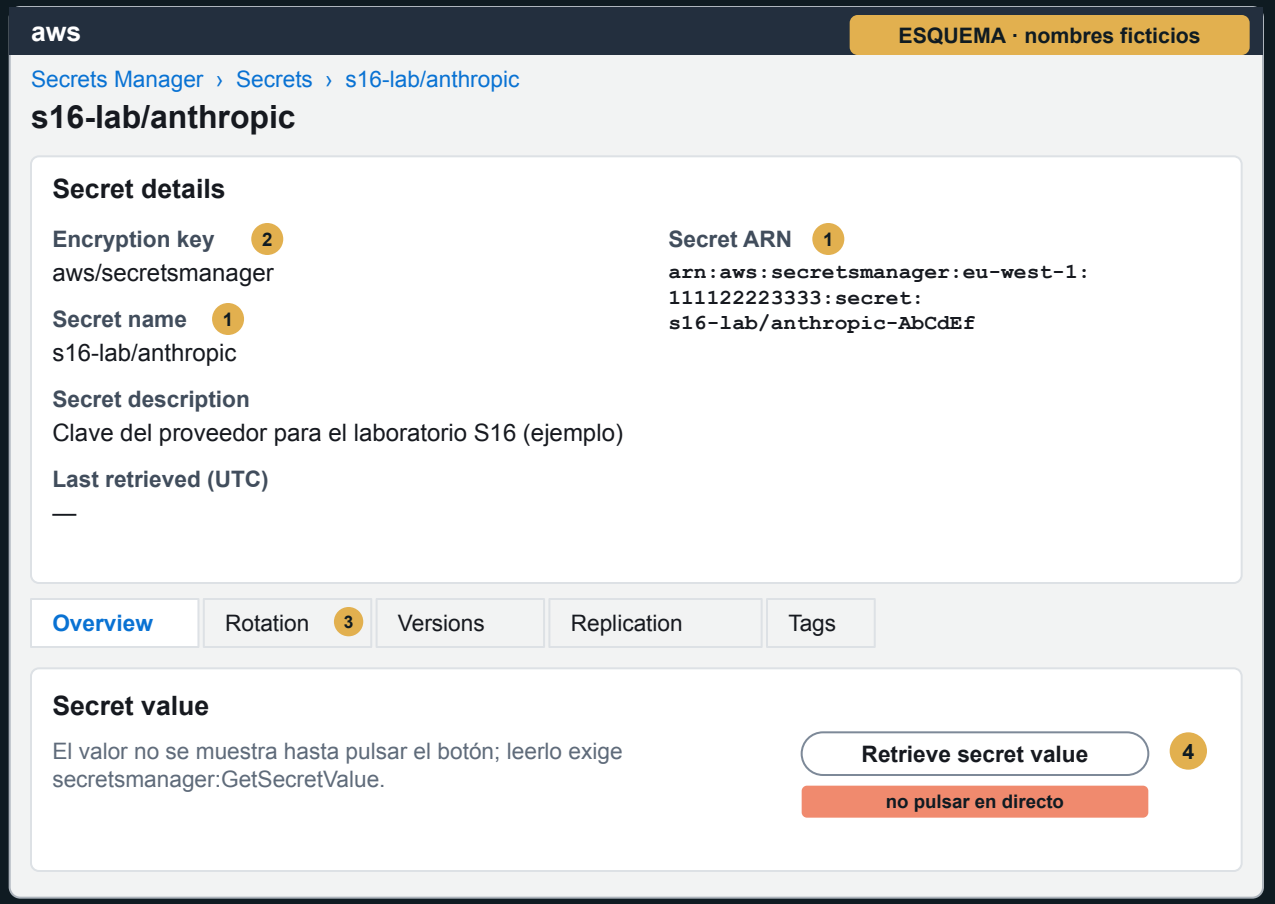
MÁS CONTROL → MENOS ADMINISTRACIÓN

	Amazon EC2	ECS con Fargate (elegido hoy)	AWS Lambda (S17)
UNIDAD	Máquina virtual (instancia)	Tarea: uno o varios contenedores	Función que responde a un evento
ADMINISTRAMOS	SO, parches, Docker, el proceso de la API y el escalado	Imagen, task definition, red y roles	Código, memoria, permisos y desencadenadores
ESCALA	Auto Scaling group: instancias en minutos	Servicio ECS: más tareas en segundos o minutos	Automática por petición, desde cero
PAGAMOS	Por segundo encendida, haya tráfico o no (más EBS)	vCPU y GB por segundo mientras la tarea vive (mín. 1 min)	Por petición y por milisegundo de ejecución según la memoria
LÍMITES	Los del tipo de instancia; admite GPU	Hasta 16 vCPU y 120 GB por tarea; sin GPU	15 min por invocación; hasta 10.240 MB de memoria
ENCAJA CON	Control total, GPU, software especial, carga constante	APIs y workers en contenedor siempre disponibles	Tráfico esporádico, eventos y APIs pequeñas

IDEA GUÍA No hay una opción mejor: hay una que encaja con el tráfico, la duración del trabajo y lo que queremos administrar.

Secrets Manager: la clave fuera de la imagen

Guarda valores sensibles cifrados con KMS y controla con IAM quién puede leerlos. En clase mostramos metadatos y referencias; nunca pulsamos «Retrieve secret value».



CÓMO LLEGA EL VALOR A LA API

Secreto cifrado → ECS lo inyecta al arrancar → La API llama al modelo

Lo lee el execution role (GetSecretValue) y llega al contenedor como `ANTHROPIC_API_KEY`.

1. **Nombre y ARN** La task definition guarda el ARN, que termina en 6 caracteres aleatorios.
2. **Cifrado** Clave aws/secretsmanager de KMS; una clave propia exige kms:Decrypt.
3. **Rotación** Cambiar el valor periódicamente. Las tareas en marcha conservan el anterior: hay que desplegar de nuevo.
4. **Valor** Leerlo exige permiso explícito. En clase no se muestra.

COSTE 0,40 USD por secreto y mes + 0,05 USD por 10.000 llamadas (eu-west-1, tarifas del 17/10/2026).

IDEA GUÍA Una variable de entorno no es un secreto por sí misma: importa de dónde viene, quién la lee y que no quede en imagen, Git ni capturas.

Execution role y task role: quién usa cada permiso

Una tarea tiene dos roles. ECS usa el execution role para prepararla y arrancarla; nuestro código usa el task role cuando llama a servicios de AWS mientras se ejecuta.

EXECUTION ROLE · lo usa el agente de ECS



Rol de ejecución de la tarea

Confía en ecs-tasks.amazonaws.com. Actúa antes y durante el arranque.

ECR

ecr:GetAuthorizationToken, BatchGetImage… · descargar la imagen



Secrets Manager

secretsmanager:GetSecretValue · leer el secreto al arrancar



CloudWatch Logs

logs:CreateLogStream, PutLogEvents · enviar los logs



KMS (solo con clave propia)

kms:Decrypt · descifrar el secreto

TASK ROLE · lo usa nuestro código



Nuestra API S16

No llama a ningún servicio de AWS: su task role no tiene permisos. La clave del modelo le llega como variable inyectada.

EJEMPLOS EN LOS QUE SÍ HARÍA FALTA



Leer un adjunto: s3:GetObject sobre un bucket concreto.



Invocar un modelo en Bedrock (S17): bedrock:InvokeModel.

OPERADOR tu usuario o rol en la consola: crea, cambia y retira los recursos.

`ResourceInitializationError: unable to pull secrets or registry auth` → revisar execution role, ARN, región, salida de red o KMS; no el task role.

IDEA GUÍA Dar el permiso al rol equivocado no arregla nada: primero identificamos quién hace la llamada que falla.

AMAZON CLOUDWATCH

CloudWatch: logs, métricas y alarmas

Los logs cuentan qué pasó en cada petición; las métricas resumen el comportamiento en el tiempo; una alarma vigila una métrica y avisa cuando cruza un umbral.



LÍNEA DE LOG DE NUESTRA API · forma real del registro, valores de ejemplo

```
{"request_id": "6f1c2d9e-…", "version": "2026-11-12.1", "execution": "real", "status": 200, "duration_ms": 842.5}
```

Logs

Grupo con retención de 7 días en nuestra plantilla; por defecto un grupo no caduca. Un stream por tarea.

```
fields @timestamp, status, duration_ms
| filter request_id = "6f1c2d9e-…"
```

Métricas

ECS publica CPUUtilization y MemoryUtilization por servicio (espacio AWS/ECS). Un filtro de métricas puede contar respuestas 5xx en los logs.

Alarmas

Vigilan una métrica y cambian entre OK, ALARM e INSUFFICIENT_DATA. Al cambiar, notifican, por ejemplo por SNS a un correo.

COSTE Ingesta 0,57 USD/GB y almacenamiento 0,03 USD/GB-mes en eu-west-1 (17/10/2026). Métricas personalizadas y alarmas tienen tarifa propia.

IDEA GUÍA Con el request_id de la respuesta encontramos su línea de log: estado, duración y versión, sin guardar el texto del usuario ni la clave.

BILLING AND COST MANAGEMENT

Factura, estimación, presupuesto y alerta

Son herramientas distintas: una mira lo ya consumido, otra estima antes de crear y otras vigilan mientras los recursos existen. Billing and Cost Management es global y exige permisos de facturación.

LO YA CONSUMIDO → ANTES DE CREAR

Bills · factura

Lo que AWS ha facturado cada mes, por servicio y región. Es consumo pasado: retirar recursos no lo borra.

`Billing and Cost Management › Bills`

Cost Explorer · análisis

Coste por servicio, región o etiqueta, con previsión. Tras activarlo puede tardar hasta 24 h en mostrar datos.

`… › Cost Explorer`

Budgets · presupuesto y alerta

Un importe con umbrales de gasto real o previsto que avisan por correo o SNS. La alerta avisa; no apaga recursos.

`… › Budgets › Create budget`

Pricing Calculator · estimación

Estimar antes de crear nada. Es pública y no necesita cuenta.

`calculator.aws`

PARTIDAS QUE APARECEN CON NUESTRA API

Cómputo · IPv4 pública · Almacenamiento · Logs · Secretos · Tráfico de salida · Inferencia · aparte

Factura ≠ estimación ≠ presupuesto ≠ alerta. Una estimación usa tarifas y cantidades supuestas; la factura refleja el uso real; el presupuesto fija un límite de referencia; la alerta solo avisa.

IDEA GUÍA Una alerta de presupuesto no detiene nada: parar o retirar recursos es una acción nuestra.

COSTE MENSUAL

730 horas de nuestra API: 13,78 USD sin inferencia

Estimación con tarifas públicas de eu-west-1 (Irlanda) leídas el 17/10/2026 y cantidades supuestas. USD sin impuestos, descuentos ni créditos. No es una factura.

13,78 USD

por mes · una tarea de 0,25 vCPU y 0,5 GB encendida 730 horas · sin inferencia

eu-west-1 · Irlanda

tarifas del 17/10/2026

cantidades supuestas · no es una factura



92 % es tiempo encendido: CPU, memoria e IPv4

8 % resto

CPU	`0,25 vCPU × 730 h × 0,04048 USD/vCPU-h`	`7,3876`
Memoria	`0,5 GB × 730 h × 0,004445 USD/GB-h`	`1,6224`
IPv4 pública	`1 IP × 730 h × 0,005 USD/IP-h`	`3,6500`
Logs	`1 GB ingerido × 0,57 + 1 GB-mes × 0,03`	`0,6000`
Secreto	`1 × 0,40 + 2 lecturas × 0,000005`	`0,4000`
Salida a Internet	`1 GB facturable × 0,09`	`0,0900`
ECR	`0,25 GB-mes × 0,10`	`0,0250`
Total (redondeo al final)		`13,7750 → 13,78 USD`

SUPUESTOS

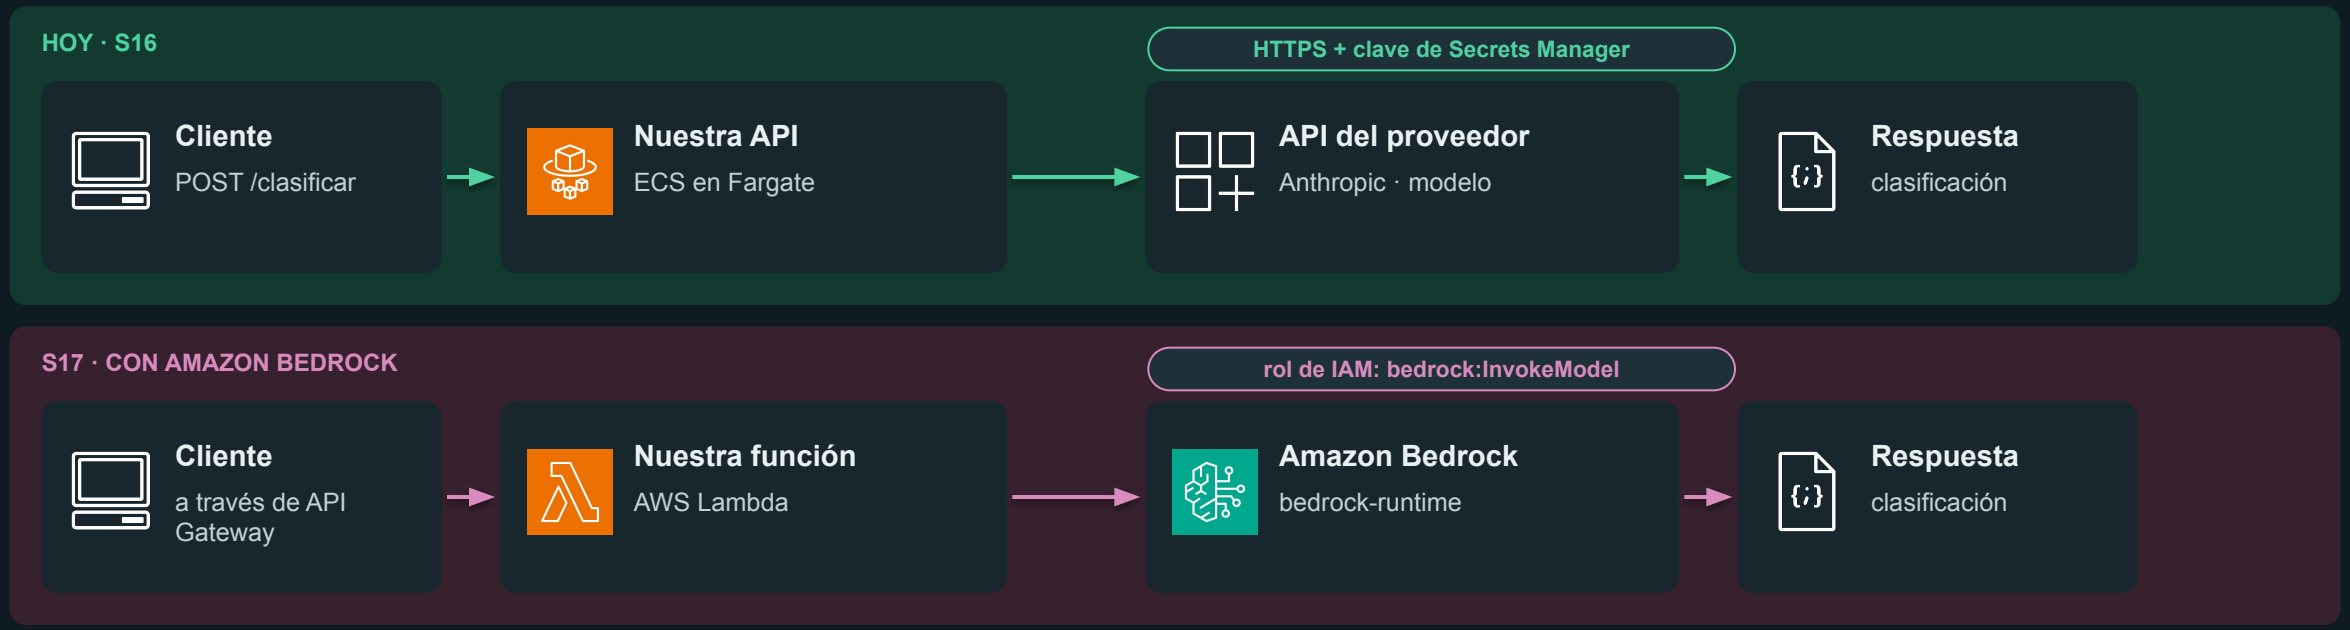
- Una tarea Linux x86 con almacenamiento efímero incluido.
- 0,25 GB en ECR, 1 GB de logs, un secreto con dos lecturas y 1 GB de salida ya facturable.
- No se descuenta el tramo gratuito de tráfico.
- Sin NAT, balanceador, base de datos ni KMS propia: si se añaden, se suman.
- Inferencia aparte: tokens × tarifa del modelo.

IDEA GUÍA El 92 % del mes es tiempo encendido. Apagar cuando no se usa es la primera optimización.

IA GESTIONADA

Alojar nuestra API no es lo mismo que consumir un modelo

Fargate ejecuta nuestro código. El modelo vive en un servicio del proveedor y lo llamamos por API. Hoy nuestra API llama a Anthropic; en S17 la conectaremos con Amazon Bedrock.



Qué alojamos

Código, contenedor o función, red, logs y permisos. Pagamos cómputo y recursos.

Qué consumimos

Capacidad de inferencia del proveedor por API. Pagamos tokens o capacidad reservada.

Qué cambia con Bedrock

Autenticación con IAM en lugar de una clave externa, factura en AWS y disponibilidad por región.

IDEA GUÍA Ningún modelo se descarga en nuestra imagen: el contenedor solo contiene la aplicación que lo llama.

OTRAS NUBES

Las mismas funciones en AWS, Azure y Google Cloud

Correspondencias por función para orientarse. No implican las mismas APIs, límites, precios ni prestaciones.

	aws	Microsoft Azure	Google Cloud
Máquina virtual	Amazon EC2	Azure Virtual Machines	Compute Engine
Contenedores gestionados	Amazon ECS + Fargate	Azure Container Apps	Cloud Run
Funciones	AWS Lambda	Azure Functions	Cloud Run functions
Almacenamiento de objetos	Amazon S3	Azure Blob Storage	Cloud Storage
Red privada	Amazon VPC	Azure Virtual Network	VPC
Identidad y permisos	AWS IAM	Microsoft Entra ID + Azure RBAC	Cloud IAM
Base de datos relacional	Amazon RDS	Azure SQL Database	Cloud SQL
IA gestionada	**Amazon Bedrock**	**Microsoft Foundry**	**Vertex AI**

IDEA GUÍA Elegimos nube por datos, identidad, región, modelos, operación y coste de la arquitectura completa, no por el número de servicios.

PRÁCTICA

Práctica: desplegar la API con Docker

Los ejercicios de estas sesiones no son obligatorios, según confirmó Laura el 4 de noviembre. Si decides hacerla, este es el recorrido y lo que debe contener la entrega.

ENUNCIADO DE S16 · ENCARGO DE EJERCICIOS DEL 10 DE AGOSTO

«Sesión 16 Cloud deployment: Desplegar una aplicación con Docker.»

La concreción con ECR, ECS/Fargate y Secrets Manager procede del enunciado enviado por José el 28/09.

Dedicación 4–6 horas con cuenta, permisos y entorno preparados.

Punto de partida S16-inicio.zip, con la API ya preparada.

Ayuda Guía del alumno con comandos y proyecto de referencia.

1 Docker local

/health, /clasificar en demo y usuario 10001.

2 ECR

Imagen publicada con etiqueta y digest.

3 Task definition

Imagen por digest, X86_64 y secreto por ARN.

4 Red

Entrada /32 al 8000; salida 443.

5 Salud y función reales

request_id localizado en CloudWatch.

6 Coste y retirada

730 h, demo e inventario final.

SI LA HACES, LA ENTREGA INCLUYE

- Código, lock, Dockerfile y .dockerignore; procedimiento reproducible.
- Evidencia real: imagen identificada, tarea, salud y una petición funcional.
- Coste con región, fecha, tarifas, supuestos e inferencia aparte.
- Retirada e inventario: qué se eliminó, qué se conserva y por qué.

ANTES DE EMPEZAR

Crea recursos con coste: usa una cuenta de laboratorio, un presupuesto y la retirada al terminar. El modo demo sirve para practicar sin gasto, pero no sustituye la evidencia real.

IDEA GUÍA Si la haces, la prueba no es una pantalla verde: es la imagen identificada, una petición real y el inventario de lo retirado.

thePower

CIERRE

Lo que nos llevamos

1. La región y la cuenta determinan qué vemos y dónde viven los recursos.
2. IAM decide qué acción se permite sobre qué recurso; la red decide qué conexión llega.
3. EC2 con EBS es una máquina que administramos; S3 guarda objetos; Fargate ejecuta contenedores.
4. ECR guarda la imagen; ECS la describe y la mantiene; el secreto se inyecta al arrancar.
5. CloudWatch une cada petición con su log; factura, estimación, presupuesto y alerta son cosas distintas.
6. Consumir un modelo gestionado no es lo mismo que alojar nuestra API.

¿Preguntas?

PRÓXIMA SESIÓN · S17

API Gateway, AWS Lambda y Amazon Bedrock con el mismo caso de soporte.



MATERIALES DE S16

Presentación, guía del alumno, enunciado de la práctica opcional y paquetes S16-inicio y S16-referencia.