Sesión 16 · Cloud deployment: AWS basics

Desplegar una aplicación con Docker

Enunciado

Empaqueta una pequeña API de IA en un contenedor Docker y despliega la imagen en AWS con ECR y ECS/Fargate. Comprueba el servicio, protege los secretos y calcula cuánto costaría mantener los recursos activos.

Explicación completa del ejercicio

Trabajo obligatorio. Crea una API FastAPI con un endpoint de salud y otro que invoque un modelo de IA. Guarda el identificador del modelo en una variable de entorno. Prepara Dockerfile y `.dockerignore`, fija las dependencias y ejecuta el contenedor con un usuario no root.

Prueba y publica la imagen. Comprueba ambos endpoints en local y sube una versión identificable a ECR. Si construyes en un Mac con Apple Silicon, genera la imagen para `linux/amd64` o configura la tarea para ARM64. La arquitectura de la imagen y la tarea de Fargate debe coincidir.

Protege los secretos. Usa Secrets Manager o Parameter Store y referencia las claves desde la definición de la tarea. No las escribas en el código, Dockerfile o imagen. El task execution role, utilizado por ECS al arrancar, necesita leer esos secretos; no es el mismo rol que usa tu aplicación. Si utilizas una clave KMS propia, configura también su permiso de descifrado.

Limita el acceso de la demo. Basta una IP pública temporal con acceso restringido al puerto de la API y a la IP de quien la prueba. Configura la salida de red necesaria. Utiliza únicamente contenido ficticio y no envíes claves o credenciales de cliente por HTTP. Esta opción temporal no representa un despliegue público de producción.

Explica y estima. Describe el contenedor, el registro de imágenes, la red y los permisos. Calcula el coste de 730 horas en la región elegida, incluyendo CPU, memoria, ECR, logs, IPv4 pública y tráfico. Añade otros servicios solo si los has usado. Separa el coste de inferencia y declara tarifas y supuestos; no necesitas mantener el servicio un mes.

Elimina lo creado. Documenta cómo retirar tareas o servicios, imágenes, secretos, logs y recursos de red de esta práctica. Comprueba que no queden recursos cobrables. No borres recursos compartidos del laboratorio. Compara el coste mensual con el de ejecutar la demo y apagarla al terminar.

Ampliación opcional. Añade un balanceador con HTTPS y tareas en una red privada, incluyendo el coste y la limpieza de esos recursos. No es necesario incorporar S3 ni una base de datos.

Entrega y valoración. Entrega código, instrucciones o infraestructura declarativa, evidencias, cálculo de coste y pasos de limpieza. Se valorarán la repetibilidad del despliegue, la seguridad de los secretos, la compatibilidad de arquitectura y el control del gasto.

Dedicación orientativa: 4–6 horas activas con cuenta y permisos preparados.